



VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
INFORMACINIŲ SISTEMŲ INŽINERIJOS STUDIJŲ PROGRAMA

DAUGIAMAČIŲ DUOMENŲ DIMENSIJOS MAŽINIMAS

Laboratorinio darbo ataskaita

Atliko: Mantas Globys, Rugilė Macaitė, Ugnė Mockutė

VU el. p.: mantas.globys@mif.stud.vu.lt,
rugile.macaite@mif.stud.vu.lt,
ugne.mockute@mif.stud.vu.lt,

Vertino: doc. Dr. Jolita Bernatavičienė

Vilnius

2025

TURINYS

1. Darbo tikslas ir uždaviniai	4
2. Duomenų paruošimas ir išskirčių valdymas	4
2.1. Ekstremalių išskirčių šalinimas	4
2.2. Švelnių išskirčių radimas	4
3. Duomenų normavimas.....	4
4. Visų požymių aibės vizualizacija.....	5
4.1. Hlle (hessian locally linear embedding)	5
4.1.1. Hlle vizualizacija nenormuotai aibei	5
4.1.2. Hlle vizualizacija normuotai aibei	6
4.1.3. Hlle rezultatų interpretacija	7
4.2. T-sne (t-distributed stochastic neighbor embedding)	7
4.2.1. T-sne vizualizacija nenormuotai aibei.....	8
4.2.2. T-sne vizualizacija normuotai aibei	8
4.2.3. T-sne rezultatų interpretacija	9
4.3. Mds (multidimensional scaling).....	9
4.3.1. Mds vizualizacija nenormuotai aibei.....	10
4.3.2. Mds vizualizacija normuotai aibei	11
4.3.3. Mds rezultatų interpretacija	12
5. 6 požymių aibės vizualizacija	12
5.1. Hlle vizualizacija 6 požymių aibei	13
5.1.1. Hlle vizualizacija nenormuotai aibei.....	13
5.1.2. Hlle vizualizacija normuotai aibei	14
5.2. Hlle normuotos aibės hiperparametrų kaita	15
5.2.1. Kai $k = 20$	15
5.2.2. Kai $k = 30$	16
5.2.3. Kai $k = 40$	17
5.2.4. Parametrų palyginimas	18
5.3. T-sne vizualizacija 6 požymių aibei.....	18
5.3.1. T-sne vizualizacija normuotai aibei	18
5.3.2. T-sne vizualizacija nenormuotai aibei.....	19
5.4. T-sne normuotos aibės hiperparametrų kaita	20
5.4.1. Kai learning rate = 10 ir euclidean.....	20
5.4.2. Kai learning rate = 10 ir manhattan.....	21
5.4.3. Kai learning rate = 100 ir euclidean.....	22
5.4.4. Kai learning rate = 100 ir manhattan.....	22
5.4.5. Kai learning rate = 500 ir euclidean.....	23
5.4.6. Kai learning rate = 500 ir manhattan.....	23
5.4.7. Parametrų palyginimas	24
5.5. Mds vizualizacija 6 požymių aibei.....	24
5.5.1. Mds vizualizacija nenormuotai aibei.....	25
5.5.2. Mds vizualizacija normuotai aibei	25
5.6. Mds normuotos aibės hiperparametrų kaita	26
5.6.1. Mds vizualizacija su euclidean metrika.....	26
5.6.2. Mds vizualizacija su manhattan metrika	27
5.6.3. Parametrų palyginimas	28
6. Algoritmų palyginimai – privalumai ir trūkumai	28

7. Išvados	30
priedas.....	31

1. DARBO TIKSLAS IR UŽDAVINIAI

Darbo tikslas – taikant dimensijos mažinimo metodus HLLE, t-SNE ir metrinį MDS EKG daugiamačių duomenų vizualizavimui, pateikti pasirinktos aibės (tiek visų požymių, tiek atrinktų 6 požymių rinkinių) 2D projekcijas ir jų interpretaciją. Metodai taikomi tiek min–max normuotai, tiek nenormuotai duomenų aibei, siekiant įvertinti klasių atskiriamumą, išskirčių poveikį ir nustatyti, kokios parametrų reikšmės bei duomenų paruošimas lemia informatyviausią vizualizaciją.

1. Paruošti duomenis: užpildyti trūkstamas reikšmes (mediana per klasę), identifikuoti ekstremalias išskirtis ($3 \times \text{IQR}$) ir švelnias ($1.5 \times \text{IQR}$), taikyti min–max normavimą.
2. Sugeneruoti 2D projekcijas su HLLE, t-SNE ir metrinio MDS normuotai ir nenormuotai aibei (visų požymių ir 6 požymių rinkiniams).
3. Palyginti normuotos ir nenormuotos projekcijas.
4. Ištirti hiperparametrų įtaką.
5. Įvertinti metodų privalumus ir trūkumus bei suformuluoti išvadas remiantis eksperimentais.

2. DUOMENŲ PARUOŠIMAS IR IŠSKIRČIŲ VALDYMAS

Pradiniame duomenų rinkinyje atlikta atranka – iš kiekvienos EKG dūžio klasės (0, 1, 2) atsitiktinai paimta po 500 įrašų, taip suformuojant analizės aibę, sudarytą iš 1500 įrašų ir 31 požymio.

2.1. Ekstremalių išskirčių šalinimas

Ekstremalios išskirtys buvo identifikuotos naudojant bendrą kaukę pagal $3 \times \text{IQR}$ (interkvartilio diapazono) taisyklę, taikomą visiems 31 skaitiniams požymiams. Šis metodas skirtas identifikuoti tik labai nutolusius duomenų taškus. Vizualizacijose jos žymimos „*“ simboliu.

- Ekstremalių įrašų skaičius: 951

2.2. Švelnių išskirčių radimas

Paruoštoje aibėje papildomai buvo pažymėtos švelnios išskirtys ($1.5 \times \text{IQR}$). Šie įrašai vizualizacijose pažymėti „X“ simboliu, siekiant įvertinti jų pasiskirstymą projekcinėje (2D) erdvėje ir galimą įtaką metodų rezultatams.

- Švelnių išskirčių skaičius švariame rinkinyje: 205

3. DUOMENŲ NORMAVIMAS

Siekiant užtikrinti visų požymių palyginamumą ir pašalinti mastelio poveikį, duomenims taikytas Min–Max normavimo metodas. Šio metodo esmė – kiekvieno požymio reikšmės transformuoti į intervalą $[0;1]$, naudojant formulę:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Tokiu būdu išsaugoma duomenų pasiskirstymo forma, tačiau skirtingų kintamųjų skalės suvienodinamos. Normavimas būtinas, kai taikomi distancijos pagrindu veikiantys metodai, tokie kaip MDS ar t-SNE, nes požymiai su didesniu variacijos diapazonu gali neproporcingai daryti įtaką atstumų skaičiavimams.

Atlikus Min–Max transformaciją, gauti duomenys įgijo vienodą svorį analizei ir tapo tinkami taikyti dimensijos mažinimo algoritmus, užtikrinant jų rezultatų korektiškumą bei palyginamumą.

4. VISŲ POŽYMIŲ AIBĖS VIZUALIZACIJA

Sutvarkytam duomenų rinkiniui (po trūkstamų reikšmių užpildymo ir išskirčių identifikavimo) buvo taikyti trys dimensijos mažinimo metodai – Hessian Locally Linear Embedding (HLLE), t-SNE ir metrinis MDS. Kiekvienas metodas pritaikytas tiek normuotai (Min–Max), tiek nenormuotai duomenų aibei, siekiant įvertinti mastelio poveikį projekcijų kokybei ir klasių atskyrimui. Šiame etape išskirtys nebuvo šalinamos, o pažymėtos pagal IQR kriterijų:

- Švelnios išskirtys – reikšmės už $1.5 \times \text{IQR}$ ribų,
- Ekstremalios išskirtys – reikšmės už $3 \times \text{IQR}$ ribų.

Jos buvo vaizduojamos grafikuose atskirais simboliais, kad būtų galima vertinti, kaip šie taškai pasiskirsto mažesnės dimensijos erdvėje.

4.1. HLLE (Hessian Locally Linear Embedding)

Hessian Locally Linear Embedding (HLLE) metodas yra netiesinės dimensijos mažinimo technika, paremta prielaida, kad aukštesnės dimensijos duomenys yra išsidėstę daugdaroje (angl. manifold), kurios lokali geometrija gali būti aproksimuojama tiesiniais ryšiais tarp artimiausių duomenų taškų. HLLE algoritmas išplečia klasikinį Locally Linear Embedding (LLE) principą, papildydamas jį Heseno operatoriaus skaičiavimu, kuris leidžia tiksliau modeliuoti nelineines struktūras duomenų erdvėje ir atkurti jų topologinį tęstinumą sumažintos dimensijos erdvėje.

Metodas buvo taikytas tiek nenormuotai, tiek Min–Max normuotai požymių aibei, siekiant įvertinti mastelio įtaką įterpties kokybei ir klasių atskyrimui. Visais atvejais naudotas $k = 30$ artimiausių kaimynų parametras ir dviejų dimensijų įterptis ($\text{ndim} = 2$).


Analizė buvo įgyvendinta programavimo aplinkoje R, naudojant paketą `dimRed`, kuris užtikrina vieningą įvairių dimensijos mažinimo metodų taikymo struktūrą. Duomenų apdorojimo procese trūkstamos reikšmės buvo užpildytos klasės medianomis, o išskirtys identifikuotos remiantis interkvartilinio rėžio (IQR) kriterijumi ($1.5 \times \text{IQR}$ – švelnios, $3 \times \text{IQR}$ – ekstremalios), tačiau nebuvo pašalintos iš analizės. Vizualizacijos parengtos pasitelkiant `ggplot2` paketą, išskirtys pažymėtos skirtingais simboliais, o duomenų klasės – spalvomis.

4.1.1. HLLE vizualizacija nenormuotai aibei

Nenormuotos duomenų aibės HLLE projekcijoje (1 pav.) dauguma stebėjimų koncentruojasi centrinėje įterpties erdvės dalyje, o keli ekstremalūs įrašai išsidėsto atokiau nuo pagrindinio taškų masyvo. Toks pasiskirstymas rodo, kad be mastelio suvienodinimo kai kurie

požymiai, pasižymintys didesniu reikšmių diapazonu (pvz., signal_mean, T_val), dominuoja atstumo skaičiavimuose. Dėl to artimiausių kaimynų struktūra tampa iškreipta, o HLLE algoritmas praranda gebėjimą atkurti globalią daugdarinę formą.

Projekcija nesuformavo aiškių klasterių tarp klasių (0, 1, 2), tačiau išlaikė lokalią struktūrą, leidžiančią identifikuoti duomenų taškus, kurie nukrypsta nuo pagrindinės tendencijos. Švelnios ir ekstremalios išskirtys (pažymėtos atitinkamais simboliais) vizualiai išsiskiria iš duomenų centro, patvirtindamos jų netipinį pobūdį.




1 pav. HLLE – visų požymių nenormuotos aibės vizualizacija

4.1.2. HLLE vizualizacija normuotai aibei

Normuotos duomenų aibės HLLE projekcijoje (2 pav.) stebimas aiškesnis klasių išsidėstymas ir struktūrinis pasiskirstymas. Duomenų taškai sudaro beveik linijinę struktūrą palei pirmąją HLLE ašį (HLLE1), o klasių 0 ir 2 stebėjimai koncentruojasi priešinguose šios ašies galuose. Tai rodo, kad Min–Max normavimas efektyviai sulygino požymių mastelius ir leido algoritmui tolygiau įvertinti artimiausių kaimynų santykius.

Vis dėlto normavimas sumažino bendrą duomenų variaciją, todėl projekcija tapo suplokštėjusi, o antrosios dimensijos (HLLE2) informacinis svoris sumažėjo. Nepaisant to, normuotoje aibėje HLLE aiškiau atskleidžia klasių ribas ir išlaiko lokalią struktūrą, todėl šis variantas laikytinas informatyvesniu klasifikaciniu požiūriu.



2 pav. HLLE – visų požymių normuotos aibės vizualizacija

4.1.3. HLLE rezultatų interpretacija

Lyginant HLLE rezultatus normuotoje ir nenormuotoje aibėse, galima teigti, kad metodo veikimas yra jautrus duomenų masteliui. Nenormuotoje aibėje keli didelio mastelio požymiai nulėmė atstumo metrikos dominavimą, todėl duomenų struktūra HLLE erdvėje tapo kompaktiška ir mažiau informatyvi. Normuotoje aibėje, priešingai, pasiektas aiškesnis klasių 0 ir 2 atskyrimas bei tolygesnis taškų pasiskirstymas, nors dėl sumažintos variacijos projekcija prarado dalį erdvinio gylio.

Šie rezultatai rodo, kad tinkamas duomenų normavimas yra būtinas HLLE metodo taikymui heterogeniškuose požymių rinkiniuose. Mastelio suvienodinimas leidžia algoritmui tiksliau išlaikyti lokalius santykius tarp duomenų taškų ir pagerina projekcijos interpretaciją klasių atskyrimo kontekste.

4.2. t-SNE (t-Distributed Stochastic Neighbor Embedding)

t-SNE (t-Distributed Stochastic Neighbor Embedding) yra netiesinis dimensijos mažinimo metodas, skirtas aukštesnės dimensijos duomenų vizualizacijai dvimatėje arba trimatėje erdvėje, plačiai taikomas duomenų klasterių bei paslėptų struktūrų tyrimams.

Metodas remiasi tikimybine kaimynystės samprata: aukštos dimensijos erdvėje kiekvienam taškui apskaičiuojama tikimybė priklausyti kitiems artimiems taškams. Šios tikimybės projektuojamos į mažesnės dimensijos erdvę taip, kad būtų išlaikytas lokalus panašumas tarp duomenų taškų – artimi taškai lieka arti, o tolimi – nutolsta.


Vienas svarbiausių t-SNE parametrų yra perplexity, apibūdinantis efektyvų artimiausių kaimynų skaičių. Mažos perplexity reikšmės išryškina smulkias struktūras, o didesnės – labiau

globalius duomenų ryšius. Dėl šios priežasties t-SNE rezultatai yra labai jautrūs parametrų pasirinkimui ir duomenų masteliui.

R kalboje t-SNE metodas buvo įgyvendintas naudojant „Rtsne“ biblioteką, kuri remiasi Laurens van der Maaten ir Geoffrey Hinton pasiūlytu algoritmo modeliu. Ši biblioteka realizuoja t-SNE optimizavimo procesą pagal Kullback–Leibler divergencijos minimizavimo principą tarp tikrosios ir mažesnės dimensijos duomenų pasiskirstymo.

4.2.1. t-SNE vizualizacija nenormuotai aibei

Pateiktoje diagramoje (3 pav.) pavaizduoti EKG pūpsnių duomenų t-SNE analizės rezultatai, gauti naudojant visus požymius nenormuotoje aibėje ir nustatant perplexity = 30 parametą. Horizontalioje ašyje vaizduojama pirmoji t-SNE dimensija (tSNE1), o vertikalioje – antroji (tSNE2). Grafike matyti, kad t-SNE metodas sugebėjo gana aiškiai atskirti tris duomenų grupes. 0 klasė daugiausia susitelkusi apatinėje kairėje diagramos dalyje, 1 klasė – dešinėje pusėje, o 2 klasė išsidėsčiusi viršutinėje srityje. Šis aiškus grupių pasiskirstymas rodo, kad tarp klasių egzistuoja reikšmingi požymių skirtumai, kuriuos t-SNE metodas geba išryškinti net esant nenormuotiems duomenims. Taip pat pastebima, kad kai kurios 1 ir 0 klasės taškų sritys dalinai persidengia, kas gali rodyti tarpusavyje panašius signalų bruožus arba ribinius atvejus tarp klasių.




3 pav. t-SNE – visų požymių nenormuotos aibės vizualizacija

4.2.2. t-SNE vizualizacija normuotai aibei

Pateiktoje diagramoje (4 pav.) pavaizduoti t-SNE metodo analizės rezultatai, kai duomenys buvo normalizuoti ir naudotas perplexity = 30 parametras. Horizontalioje ašyje pateikta pirmoji t-SNE dimensija (tSNE1), o vertikalioje – antroji (tSNE2). Šiame grafike aiškiai matyti, kad duomenų normalizavimas pagerino klasių atskyrimą: klasės aiškiau susiformavusios ir mažiau persidengia nei nenormuotoje versijoje (3 pav.). 0 klasės taškai koncentruojasi dešinėje diagramos

pusėje ir sudaro kelis glaudžius pogrupius. 1 klasė dominuoja apatinėje vidurinėje dalyje, o 2 klasė aiškiai išsidėsčiusi kairėje ir viršutinėje srityse. Toks aiškus erdvinis pasiskirstymas rodo, kad normalizacija išlygino požymių mastelius, todėl t-SNE galėjo geriau išryškinti duomenų struktūrą ir panašumus tarp signalų.

Metodiškai t-SNE metodas veikia taip, kad aukštos dimensijos erdvėje esančius taškus jis projektuoja į dvimatę erdvę, išlaikydamas vietinį artimumą tarp duomenų – artimi taškai išlieka arti, o tolimi – atskiriami. Normalizuojant duomenis, kiekvienas požymis įgauna panašų svorį skaičiuojant atstumus. Dėl to gaunama labiau subalansuota ir reprezentatyvi vizualizacija, kurioje matyti ryški trijų grupių struktūra. Palyginus normuotos ir nenormuotos aibės rezultatus matyti, kad duomenų normalizavimas yra svarbus žingsnis taikant t-SNE metodą, siekiant išvengti požymių dominavimo ir gauti tikslesnę EKG signalų pasiskirstymą.



4 pav. t-SNE – visų požymių normuotos aibės vizualizacija

4.2.3. t-SNE rezultatų interpretacija

Palyginus normuotos ir nenormuotos aibės vizualizacijas matyti, kad t-SNE metodas su nenormuotais duomenimis buvo prastesnis (klasės persidengia, taškai susimaišę), nes didesnės reikšmės turintys požymiai dominavo atstumo skaičiavime ir iškraipė tikrąjį duomenų pasiskirstymą. Priešingai, su normuota duomenų aibe, t-SNE sugeneravo ženkliai geresnį vaizdą, kuriame EKG pūpsnių klasės buvo ryškiai atskirtos į vientisus klasterius. Normalizavimas suvienodino visų požymių svorį, todėl t-SNE galėjo tiksliau įvertinti duomenis.

4.3. MDS (Multidimensional Scaling)

Multidimensional Scaling (MDS) – tai tiesinis dimensijos mažinimo metodas, taikomas daugiamačių duomenų vizualizacijai mažesnės dimensijos erdvėje, siekiant išlaikyti pradinis porinius atstumus tarp objektų. Šis metodas plačiai taikomas statistikoje ir duomenų analizėje, kai siekiama įvertinti objektų panašumų arba skirtumų struktūrą vizualiai interpretuojamoje formoje.

Pagrindinė MDS idėja – iš duomenų atstumo matricos (dažniausiai apskaičiuotos pagal Euklido arba Manheteno metriką) sukonstruoti tokią taškų konfigūraciją dvimatėje erdvėje, kurioje atstumai tarp taškų kuo tiksliau atspindėtų pradinės duomenų distancijas. Tokiu būdu išsaugoma esminė duomenų topologinė informacija, leidžianti vizualiai įvertinti stebinių artumą.


MDS metodas egzistuoja dviejose pagrindinėse versijose: metrinis (Metric MDS) ir nemetrinis (Non-metric MDS). Šiame darbe taikytas metrinis MDS, kuris siekia išsaugoti absoliučias atstumų reikšmes, todėl jo principai yra artimi klasikinei komponentų analizei (PCA).

Analizė buvo įgyvendinta R aplinkoje, naudojant funkciją `cmdscale()` iš bazinio paketo MASS. Duomenys buvo analizuojami dviem būdais – nenormuoti ir normuoti (Min–Max), siekiant įvertinti mastelio poveikį MDS rezultatams. Naudota Euklido metrika, o gautos įterptys atvaizduotos dviejose dimensijose (MDS1 ir MDS2). Išskirtys, identifikuotos pagal interkvartilinio režio (IQR) metodą, nebuvo pašalintos, bet pažymėtos skirtingais simboliais (švelnios ir ekstremalios), siekiant įvertinti jų padėtį projekcijos erdvėje.

4.3.1. MDS vizualizacija nenormuotai aibei

Nenormuotos duomenų aibės MDS projekcijoje (5 pav.) matyti, kad dauguma taškų yra susitelkę netoli ašies pradžios, tačiau pastebimas reikšmingas išsidėstymas išilgai MDS1 ašies, ypač 1 klasės (žali taškai) atveju, kur stebėjimai išsibarstę plačiau ir apima reikšmingai didesnę verčių diapazoną. Tuo tarpu 0 (raudona) ir 2 (mėlyna) klasės koncentruojasi centre, tačiau jų taškai persidengia, o aiškių klasterių ribų neatsiskleidžia.

Toks rezultatų pasiskirstymas rodo, kad be mastelio suvienodinimo keli požymiai, turintys didesnę skaitinių reikšmių diapazoną, dominuoja atstumo skaičiavimuose. Dėl to MDS1 dimensija įgauna neproporcingai didelį svorį, o mažesnio mastelio požymiai netenka įtakos projekcijai. Ekstremalios išskirtys (pažymėtos žvaigždutėmis) pasirodo toliau nuo pagrindinės duomenų grupės ir iškreipia bendrą erdvės formą, kas rodo padidėjusį heterogeniškumą nenormuotu atveju.




5 pav. MDS – visų požymių nenormuotos aibės vizualizacija

4.3.2. MDS vizualizacija normuotai aibei

Normuotos duomenų aibės MDS projekcijoje (6 pav.) duomenų struktūra tampa aiškesnė – trys klasės (0, 1, 2) sudaro išskiriamus, nors dalinai persidengiančius regionus. 0 klasės (raudona) stebėjimai sudaro tankų telkinį centrinėje dalyje, o 1 (žalia) ir 2 (mėlyna) klasės pasiskirsto priešinguose MDS1 ašies galuose. Šis pasiskirstymas rodo, kad Min–Max normavimas padėjo subalansuoti požymių mastelius ir sumažino didelio variacijos požymių dominavimą, dėl ko porinių atstumų struktūra tapo stabilesnė ir labiau reprezentatyvi.

Taip pat galima pastebėti, kad švelnios išskirtys (pažymėtos X) išsidėsto klasių ribose, o ekstremalios (žvaigždutės) – toliau nuo pagrindinių telkinių. Tai gali rodyti signalų triukšmo ar fiziologinio variantiškumo poveikį, tačiau struktūriškai jos išlieka susijusios su savo klasės kontekstu.

Lyginant su nenormuota projekcija, normuoto MDS rezultatas išryškina aiškesnę klasių atskyrimą ir subalansuotą taškų pasiskirstymą be kraštinių verčių dominavimo. Tai patvirtina, kad mastelio suvienodinimas yra būtinas norint užtikrinti MDS metodo stabilumą ir rezultatų interpretacijos patikimumą.



6 pav. MDS– visų požymių normuotos aibės vizualizacija

4.3.3. MDS rezultatų interpretacija

MDS metodo rezultatai rodo, kad duomenų mastelis turi reikšmingą įtaką vizualizacijos struktūrai. Nenormuotos aibės atveju projekcijoje dominuoja keli didelio mastelio požymiai, todėl duomenys išsitempia viena kryptimi ir praranda proporcijas tarp klasių. Normuotoje aibėje, priešingai, požymių įtaka tampa subalansuota, o klasės išsidėsto labiau diferencijuotai.

Tai leidžia daryti išvadą, kad metrinis MDS efektyviau atspindi duomenų panašumų struktūrą, kai požymiai yra mastelio požiūriu suvienodinti. Tokiu atveju duomenų projekcija tampa aiškesnė, klasių atskyrimas – ryškesnis, o išskirtys netenka neproporcingos įtakos atstumų metrikai.

5. 6 POŽYMIŲ AIBĖS VIZUALIZACIJA

Antrajame etape atlikta sumažintos požymių aibės analizė, siekiant įvertinti, kaip dimensijos mažinimo metodai veikia su mažesniu, tačiau informatyviausiu požymių rinkiniu. Iš visų 31 požymio buvo atrinkti šeši požymiai: RR_l_0, RR_r_0, RR_l_0_RR_l_1, RR_r_0_RR_r_1, signal_mean ir signal_std. Šie požymiai buvo naudoti ir pirmame darbe.

Atrinkta aibė buvo apdorota tomis pačiomis etapų sekomis kaip ir visa duomenų bazė: atliktas trūkstančių reikšmių užpildymas, ekstremalių ir švelnių išskirčių identifikavimas bei Min–Max normavimas. Dimensijos mažinimui taikyti HLLE, t-SNE ir metrinis MDS metodai tiek normuotai, tiek nenormuotai aibei, siekiant įvertinti duomenų mastelio poveikį vizualizacijų rezultatams.

Šis eksperimentas leidžia palyginti, ar sumažinus požymių skaičių išlieka duomenų struktūros atskyrimas bei ar sumažintas rinkinys užtikrina pakankamą klasių atskyrimą vizualizacijos erdvėje.

5.1. HLLE vizualizacija 6 požymių aibei

Siekiant įvertinti požymių atrankos poveikį dimensijos mažinimo metodų rezultatams, Hessian Locally Linear Embedding (HLLE) algoritmas buvo pritaikytas sumažintai EKG duomenų aibei, sudarytai iš šešių požymių: `RR_l_0`, `RR_r_0`, `RR_l_0_RR_l_1`, `RR_r_0_RR_r_1`, `signal_mean` ir `signal_std`. Šie požymiai buvo paimti iš pirmojo darbo.


Analizė atlikta tiek nenormuotai, tiek Min–Max normuotai duomenų aibei, tam, kad būtų galima įvertinti mastelio poveikį HLLE metodo veikimui. Kaip ir visų požymių analizės atveju, algoritmui taikytas artimiausių kaimynų skaičius $k = 30$, kuris leidžia išryškinti lokalias duomenų struktūras, mažiau priklausomas nuo globalių pasiskirstymo savybių.

Šio etapo tikslas buvo nustatyti, ar sumažinus požymių skaičių išlieka pakankama informacija klasių atskyrimui bei ar HLLE metodas geba vizualiai atskleisti netiesines priklausomybes mažesnės dimensijos erdvėje.

5.1.1. HLLE vizualizacija nenormuotai aibei

Nenormuotos šešių požymių duomenų aibės HLLE projekcijoje (7 pav.) dauguma taškų koncentruojasi arti ašies pradžios, tačiau stebimas tam tikras išsidėstymo išsisklaidymas, ypač žemyn HLLE2 ašies kryptimi. Didžioji dalis duomenų taškų sudaro vieną centrinį telkinį, o atskiros išskirtys (pažymėtos žvaigždutėmis) išsibarstę toliau nuo pagrindinės masės, dažniausiai priklausydamos 1 klasei (žalia spalva). Klasių ribos yra menkai išreikštos – 0, 1 ir 2 klasių taškai dalinai persidengia, todėl aiškaus grupavimo nepastebima.

Toks pasiskirstymas rodo, kad nenormuotoje aibėje kai kurie požymiai, turintys didesnius reikšmių diapazonus, gali dominuoti atstumo skaičiavimuose, iškreipdami artimiausių kaimynų struktūrą. HLLE algoritmas tokiu atveju nebeatkuria ryškios duomenų daugdarinės struktūros, tačiau vis dar leidžia identifikuoti atskirus netipinius taškus, kurie išsiskiria iš bendro pasiskirstymo.




7 pav. HLLE – 6 požymių nenormuotos aibės vizualizacija

5.1.2. HLLE vizualizacija normuotai aibei

Normuotos šešių požymių aibės HLLE projekcijoje (8 pav.) duomenų taškai susitelkia itin kompaktiškame regione aplink koordinates (0; 0). Klasės visiškai persidengia, o klasterių ribos nėra identifikuojamos. Dėl to projekcija praranda informatyvumą – HLLE algoritmas šiuo atveju nesugeba atskleisti nei globalių, nei lokalių struktūrinių ryšių tarp duomenų. Ekstremalios išskirtys (žvaigždutės) pasiskirsto toliau nuo centro, tačiau jų skaičius nedidelis ir jos nedaro reikšmingos įtakos projekcijos formai.

Šį efektą galima paaiškinti tuo, kad Min–Max normavimas sumažina duomenų variaciją ir suvienodina požymių reikšmių mastelį. Kadangi HLLE metodas jautrus lokaliems skirtumams tarp taškų, šių skirtumų sumažėjimas lėmė duomenų susispaudimą į mažą regioną bei vizualinės struktūros praradimą. Tai rodo, kad per stiprus normavimas gali riboti HLLE metodo gebėjimą išlaikyti duomenų daugdarinės struktūros savybes.




8 pav. HLLE – 6 požymių normuotos aibės vizualizacija

5.2. HLLE normuotos aibės hiperparametrų kaita

Papildomai analizuota, kaip hiperparametro keitimas paveikia rezultatus, leidžiant įvertinti HLLE algoritmo jautrumą parametrų pasirinkimui. Eksperimento metu buvo naudojama normuota 6 požymių aibė, keičiant pagrindinį hiperparametrą – kaimynų skaičių (k): $k = 20$, $k = 30$, $k = 40$.

5.2.1. Kai $k = 20$


Grafike (9 pav.) ($k = 20$) pastebima, kad duomenys formuoja ištemptą struktūrą, kurioje dominuoja 1 klasė, o kai kurie 2 klasės duomenys persidengia toje pačioje srityje. Duomenų pasiskirstymas gana išskaidytas, tačiau matoma lokali struktūra, o ekstremalios išskirtys (pažymėtos žvaigždutėmis) išsidėsčiusios toliau nuo pagrindinio klasterio centro, rodydamos potencialius netipinius įrašus. Tai rodo, kad mažesnis k leidžia HLLE geriau aptikti vietinius duomenų santykius, bet gali sumažinti globalų stabilumą.



9 pav. HLLE – 6 požymių normuotos aibės vizualizacija, kai $k=20$

5.2.2. Kai $k = 30$


Grafike (10 pav.) ($k = 30$) duomenys labiau susitelkę į vieną tankų centrą, tačiau lokalias struktūros mažiau aiškios. Didesnis kaimynų skaičius suvienodina projekciją, todėl sumažėja išsklaidymas tarp taškų – tai rodo sumažintą metodo jautrumą smulkiems duomenų skirtumams. Šiuo atveju išskirtys vis dar matomos, bet jų santykinė įtaka mažėja, nes metodas labiau orientuojasi į globalią struktūrą.



10 pav. HLLE – 6 požymių normuotos aibės vizualizacija, kai $k=30$

5.2.3. Kai $k = 40$

Grafike (11 pav.) ($k = 40$) HLLE rezultatas tampa beveik susispaudęs į vieną tašką, prarandant tiek lokalią, tiek globalią duomenų struktūrą. Tai rodo, kad per didelis k lemia metodo blogėjimą — HLLE nebesugeba atkurti netiesiškumo, nes per didelis kaimynų skaičius iškreipia vietinės erdvės geometriją ir duomenys tampa per daug suvienodinti.



11 pav. HLLE – 6 požymių normuotos aibės vizualizacija, kai $k=40$

5.2.4. Parametrų palyginimas

Keičiant k (20, 30, 40) HLLE algoritme, normuotoje 6 požymių aibėje, gautas geriausias rezultatas, kai $k = 20$. Tokiu atveju išlieka aiškesnė duomenų struktūra, lokalūs skirtumai matomi, o išskirtys aiškiai identifikuojamos. Didinant k reikšmę, HLLE praranda gebėjimą išlaikyti netiesinį duomenų pasiskirstymą, todėl rezultatų interpretacija tampa mažiau informatyvi. Taigi, mažesni k dydžiai yra tinkamiausi šiai duomenų aibei, nes jie geriau atspindi sudėtingus, bet reikšmingus vidinius ryšius tarp požymių.

5.3. t-SNE vizualizacija 6 požymių aibei


t-Distributed Stochastic Neighbor Embedding (t-SNE) metodas buvo pritaikytas sumažintai šešių požymių EKG duomenų aibei, siekiant įvertinti, kaip šis netiesinis metodas geba išsaugoti lokalias duomenų struktūras mažesnės dimensijos erdvėje. t-SNE pagrįstas tikimybinio artimumo tarp taškų įvertinimu aukštesnėje ir žemesnėje dimensijoje, o projekcija optimizuojama minimizuojant Kullback–Leibler divergenciją tarp šių pasiskirstymų.

Analizė atlikta tiek nenormuotai, tiek Min–Max normuotai duomenų aibei. Normuota aibė užtikrina geresnį klasių atskyrimą ir aiškesnį lokalių struktūrų išsaugojimą, o nenormuota – labiau išskaidytą ir mažiau stabilų rezultatą dėl nevienodo požymių mastelio poveikio atstumų skaičiavimams. Tai rodo, kad t-SNE veikimas itin priklauso nuo duomenų mastelio suvienodinimo.

5.3.1. t-SNE vizualizacija normuotai aibei

Normuotos šešių požymių aibės t-SNE projekcijoje (12 pav.) duomenys sudaro tris aiškiai išreikštus klasterius, atitinkančius EKG signalų klases. 0 klasė (raudona) išsidėsto centrinėje srityje ir apatinėje kairėje diagramos dalyje, 1 klasė (žalia) – centre žemiau ir kairėje, o 2 klasė (mėlyna) – viršuje, sudarydama atskirą, kompaktišką grupę. Klasės beveik nepersidengia, o ribos tarp jų yra aiškiai matomos.

Šis rezultatas rodo, kad t-SNE efektyviai išsaugo lokalius panašumus tarp stebinių, kai duomenys yra tinkamai normuoti. Min–Max normavimas suvienodino požymių svorius, todėl nė vienas kintamasis nedomino atstumų skaičiavimuose, o projekcija atspindi realų klasių pasiskirstymą.




12 pav. t-SNE – 6 požymių normuotos aibės vizualizacija

5.3.2. t-SNE vizualizacija nenormuotai aibei

Nenormuotos šešių požymių aibės t-SNE projekcijoje (13 pav.) stebima labiau fragmentuota ir mažiau stabili struktūra. Klasės nėra aiškiai atskirtos – 0, 1 ir 2 klasių taškai persidengia keliuose regionuose, o kai kur susidaro mažos, izoliuotos grupelės. Ypač 2 klasės (mėlyni) duomenys išsibarstę įvairiose srityse, prarandant ryškų struktūrinį vientisumą.

Šį efektą galima paaiškinti tuo, kad be normavimo požymiai su didesniais reikšmių diapazonais dominavo atstumo skaičiavimuose, todėl t-SNE algoritmas negalėjo tinkamai atkurti lokalių kaimynystės santykių. Dėl to projekcija į dvimatę erdvę prarado dalį informacijos apie vidinę duomenų struktūrą. Švelnios išskirtys („X“ simboliai) išsidėsto toliau nuo pagrindinių grupių ir gali rodyti netipinius požymių derinius.

Taigi, nenormuotų duomenų atveju t-SNE prarado gebėjimą stabiliai atskirti klases, todėl normavimas yra būtinas norint užtikrinti algoritmo stabilumą ir interpretacijos tikslumą.




13 pav. t-SNE – 6 požymių nenormuotos aibės vizualizacija

5.4. t-SNE normuotos aibės hiperparametrų kaita

Eksperimente t-SNE algoritmas buvo taikytas normuotai 6 požymių aibei, keičiant pagrindinius parametrus: learning rate (10, 100, 500) ir metrikas (euclidean, manhattan).

5.4.1. Kai learning rate = 10 ir euclidean


Grafike (14 pav.) matyti, kad klasteriai pagal klases yra susiformavę, tačiau tarp jų pastebimas tam tikras persidengimas. Itin 2 klasės ir 0 klasės dalinai susimaišo viršutinėje centro dalyje. Mažas „learning rate“ (10) lemia lėtesnį mokymosi procesą, todėl t-SNE algoritmas konverguoja į lokalias struktūras, bet ne visuomet gerai atskiria globalius ryšius. Taigi, klasteriai egzistuoja, bet ribos tarp jų nėra aiškiai išreikštos.



14 pav. t-SNE metodas su euclidean ir learning rate = 10

5.4.2. Kai learning rate = 10 ir manhattan


Naudojant „Manhattan“ metriką, bendras vaizdas labai panašus į „euclidean“, tačiau pastebimas šiek tiek tolygesnis duomenų išsidėstymas. „Manhattan“ atstumas labiau tinka, kai duomenyse vyrauja absoliutiniai skirtumai tarp požymių. Šiame grafike (15 pav.) 0 ir 2 klasės atrodo šiek tiek labiau atskirtos, tačiau vis dar egzistuoja taškų persidengimas. Tai rodo, kad metrika turi įtakos lokalių struktūros jautrumui – „Manhattan“ metrika šiek tiek sumažina tankių regionų persidengimą, bet bendras grupių atskyrimas išlieka vidutinis.



15 pav. t-SNE metodas su manhattan ir learning rate = 10

5.4.3. Kai learning rate = 100 ir euclidean


Padidinus „learning rate“ iki 100, matomas reikšmingesnis globalios struktūros stabilizavimas (16 pav.). Klasteriai tapo aiškesni, jų ribos ryškesnės ir mažesnis persidengimas lyginant su prieš naudotais parametrais (14 pav., 15 pav.).



16 pav. t-SNE metodas su euclidean ir learning rate = 100

5.4.4. Kai learning rate = 100 ir manhattan


Panašiai kaip ir ankstesnis atvejis, šis grafikas (17 pav.) rodo stabilias struktūras, tačiau „Manhattan“ metrika čia labiau suspaudžia 2 klasės taškus viršutinėje dalyje. Vis dėlto grupės išlieka atpažįstamos, o bendras vaizdas rodo tinkamą kompromisą tarp lokalios ir globalios struktūros.



17 pav. *t-SNE* metodas su manhattan ir learning rate = 100

5.4.5. Kai learning rate = 500 ir euclidean

Šiame grafike (18 pav.) vis dar galima aiškiai identifikuoti tris grupes, tačiau vidiniai jų kontūrai tampa mažiau tankūs. Tai rodo, kad per didelis „learning rate“ gali sukelti struktūrinių santykių praradimą tarp artimų taškų.




18 pav. *t-SNE* metodas su euclidean ir learning rate = 500

5.4.6. Kai learning rate = 500 ir manhattan

Šis grafikas (19 pav.) rodo didžiausią skirtumą tarp grupių, tačiau tuo pačiu – didžiausią išsibarstymą. „Manhattan“ metrika kartu su aukštu „learning rate“ sukuria labai ištemptą

struktūrą, kurioje globalūs ryšiai yra išsaugoti, bet lokalūs – prarasti. 1 klasė tampa labiau atskirta, 0 ir 2 klasės susimaišo dalyje ploto.



19 pav. t-SNE metodas su manhattan ir learning rate = 500

5.4.7. Parametrų palyginimas

Remiantis visų grafikų analize, matoma, kad metrikos parametrai didelės įtakos neturi. Euclidean metrika suteikia labiau subalansuotą klasterių struktūrą, tinkančią, kai duomenų požymiai yra tęstiniai ir normuoti. Manhattan metrika duoda panašius, bet kiek labiau išsisklaidžiusius rezultatus, tinkamus, jei požymiai turi stipresnius lokalius skirtumus. Tačiau „Learning rate“ įtaka itin pastebima. Mažas „learning rate“ (10) lemia silpną globalų atskyrimą – klasteriai egzistuoja, bet persidengia. Vidutinis „learning rate“ (100) duoda optimalų balansą tarp lokalių ir globalių struktūrų, todėl klasteriai aiškiausi. Didelis „learning rate“ (500) sukelia per didelį išsisklaidymą – struktūra tampa mažiau aiški.

Taigi, optimaliausi rezultatai gauti naudojant euclidean metriką ir learning rate = 100. Šis derinys suteikė geriausią klasterių atskyrimą, išlaikant tiek lokalių, tiek globalų duomenų struktūros stabilumą. Tokie nustatymai leidžia t-SNE efektyviausiai vizualizuoti duomenis, išsaugant tarpusavio atstumų santykius ir aiškiai atskiriant klases.

5.5. MDS vizualizacija 6 požymių aibei


Šiame etape EKG duomenų, sudarytų iš šešių požymių (RR_l_0, RR_r_0, RR_l_0_RR_l_1, RR_r_0_RR_r_1, signal_mean, signal_std), aibė buvo vizualizuota taikant metrinį daugiamačio skaliavimo (MDS, Multidimensional Scaling) metodą. Analizė atlikta tiek nenormuotai, tiek Min–Max normuotai duomenų aibei, siekiant įvertinti mastelio poveikį duomenų projekcijai ir klasių atskyrimui dvimatėje erdvėje. MDS metodas pagrįstas siekiu atkurti tokią taškų konfigūraciją, kurioje poriniai atstumai tarp objektų išlieka kuo artimesni pradinio duomenų erdvėje

apskaičiuotiems atstumams. Atstumai buvo skaičiuoti pagal Euklido metriką, o vizualizacijos rezultatai pateikti atskirai normuotai ir nenormuotai aibei.

5.5.1. MDS vizualizacija nenormuotai aibei

Nenormuotos šešių požymių aibės MDS projekcijoje (20 pav.) pastebima, kad duomenų taškai pasiskirstę labai nevienodai. Didžioji jų dalis koncentruojasi viename regione (dešinėje pusėje, ties $MDS1 \approx 0$), o likusi – ypač 1 klasės taškai – išsibarstę plačiai per visą plotą, su reikšmėmis, viršijančiomis 500 pagal MDS2 ir -750 pagal MDS1. Tai rodo, kad kai kurie požymiai turi žymiai didesnius mastelius ar reikšmes, todėl nenormuotas duomenų rinkinys yra dominuojamas kelių kintamųjų su didelėmis reikšmėmis. Tokia disproporcija lemia, kad MDS daugiausia dėmesio skiria šių požymių įtakai, iškreipdamas kitų dimensijų santykius.

Dėl šios priežasties klasterių struktūra tampa sunkiai interpretuojama: klasės nėra aiškiai atskirtos, o duomenų masteliai stipriai išbalansuoti. Ypač ryškūs 1 klasės ekstremalios išskirtys, išsidėsčiusios toli nuo pagrindinės masės – tai rodo, kad ši klasė turi labai didelę variaciją kai kuriuose požymiuose, galimai dėl vienetų skirtumo ar ekstremalių reikšmių poveikio.




20 pav. MDS – 6 požymių nenormuotos aibės vizualizacija

5.5.2. MDS vizualizacija normuotai aibei

Normuotos šešių požymių aibės MDS grafikas (21 pav.) kardinaliai pasikeičia lyginant su nenormuotos aibės grafiku (20 pav.). Šiame grafike taškai išsidėsto tolygiau, be ekstremalių nuokrypių MDS ašyse. Dabar visos trys klasės pasiskirsto aiškiau: 1 klasės taškai linke koncentruotis kairėje, 2 – dešinėje, o 0 – centre. Toks pasiskirstymas rodo, kad normavimas panaikina požymių mastelio dominavimą ir leidžia MDS algoritmui vertinti visus požymius

vienodai. Dėl to atskiri duomenų klasteriai tampa labiau interpretuojami ir matomos aiškesnės tarpusavio priklausomybės.

Be to, galima pastebėti, kad ekstremalios išskirtys (žymimi „*“) dabar išsidėsčiusios arčiau pagrindinės duomenų masės, o tai rodo, kad jų poveikis bendram struktūros vaizdui sumažėjo.



21 pav. MDS – 6 požymių normuotos aibės vizualizacija

5.6. MDS normuotos aibės hiperparametrų kaita


Šiame etape buvo nagrinėjamas MDS (Multidimensional Scaling) metodo jautrumas atstumo matavimo metrikai. Eksperimente algoritmas taikytas normuotai šešių požymių EKG duomenų aibei, naudojant dvi skirtingas metrikas: Euklido (euclidean) ir Manhatano (Manhattan).

MDS vizualizacijos rezultatai tiesiogiai priklauso nuo pasirinktos atstumo metrikos, kuri lemia, kaip poriniai taškų skirtumai aukštesnėje dimensijoje bus atvaizduoti dvimatėje erdvėje. Euklido atstumas matuoja tiesiausią kelią tarp taškų (skirtumai keliami kvadratu), todėl yra jautresnis dideliems pokyčiams bet kurioje dimensijoje. Tuo tarpu Manhatano atstumas (L1 norma) matuoja atstumą kaip absoliučių skirtumų sumą, dėl to yra mažiau jautrus pavieniams dideliems nuokrypiams ir labiau pabrėžia bendrą taškų pasiskirstymą.

5.6.1. MDS vizualizacija su euclidean metrika

Normuotos šešių požymių aibės MDS projekcijoje, taikant Euklido metriką (22 pav.), stebimas gana aiškus ir kompaktiškas duomenų pasiskirstymas. 1 klasė sudaro ryškią struktūrą kairėje grafiko dalyje, 0 klasė išsidėsto centre, o 2 klasė – dešinėje, šiek tiek labiau pasklidusi, bet vis dar atpažįstama kaip atskiras telkinys.


Klasės iš esmės nepersidengia, o jų ribos aiškios. Šis rezultatas rodo, kad Euklido metrika leidžia suformuoti labiau kompaktiškus ir globaliai atskirtus klasterius, atspindinčius pagrindinę duomenų struktūrą.



22 pav. MDS – normuota 6 požymių aibė, euclidean metrika

5.6.2. MDS vizualizacija su Manhattan metrika

Naudojant Manhatano metriką (23 pav.), duomenų taškai išsidėsto platesniame regione, o klasteriai tampa mažiau kompaktiški. 0 klasė (raudona) išlieka centrinėje dalyje, tačiau 1 ir 2 klasės labiau persidengia ir atrodo išsiplėtusios į šonus. Be to, pastebimas padidėjęs duomenų išsibarstymas – kai kurie taškai nutolsta nuo pagrindinių grupių. Tai rodo, kad Manhatano metrika labiau pabrėžia lokalius skirtumus, todėl duomenų struktūra tampa išskaidyta, o klasių ribos mažiau apibrėžtos. Vis dėlto ši metrika leidžia geriau pastebėti duomenų variantiškumą ir galimas išskirtis, ypač švelnias ar ekstremalias.



23 pav. MDS – normuota 6 požymių aibė, manhattan metrika

5.6.3. Parametrų palyginimas

Atlikti eksperimentai parodė, kad atstumo metrikos pasirinkimas turi esminės įtakos MDS rezultatų interpretacijai. Naudojant Euklido metriką, duomenys formuoja tankesnius, kompaktiškus telkinius, kuriuose aiškiai išsiskiria trys pagrindinės EKG signalų klasės. Tuo tarpu Manhatano metrika sukuria platesnį, labiau išsisklaidžiusį pasiskirstymą, išryškindama duomenų variantiškumą ir išskirčių buvimą.

Abiem atvejais išlieka bendra trijų klasių struktūra, tačiau Euklido metrika labiau tinka globaliai struktūrai ir klasių identifikavimui, o Manhatano metrika – duomenų variacijos ir išskirčių analizei.

6. ALGORITMŲ PALYGINIMAI – PRIVALUMAI IR TRŪKUMAI

Šiame skyriuje atliktas trijų dimensijos mažinimo metodų – Hessian Locally Linear Embedding (HLLE), t-Distributed Stochastic Neighbor Embedding (t-SNE) ir Multidimensional Scaling (MDS) – palyginimas, siekiant įvertinti jų efektyvumą vizualizuojant EKG duomenis. Vertinimas atliktas normuotoje šešių požymių duomenų aibėje, kurioje buvo pažymėtos švelnios ir ekstremalios išskirtys, tačiau jos nebuvo pašalintos, kad būtų galima stebėti algoritmų jautrumą netipiniams taškams.

Išskirtys buvo nustatytos pagal tarpkvartilinio nuotolio (IQR) metodiką: reikšmės už $1,5 \times \text{IQR}$ ribų buvo pažymėtos kaip švelnios išskirtys, o už $3 \times \text{IQR}$ – kaip ekstremalios. Šis požiūris leido atskirti vidines (duomenų viduje esančias, „X“ simboliais pažymėtas) ir išorines

(pašalines, pažymėtas žvaigždutėmis „*“) išskirtis, kurios vėliau buvo įtrauktos į vizualizacijų vertinimą.

Siekiant kiekybiškai įvertinti algoritmų gebėjimą išsaugoti duomenų struktūrą, buvo apskaičiuoti du kokybės rodikliai: trustworthiness ir continuity. Pirmasis matuoja, kiek lokalių kaimynystės ryšių iš aukštos dimensijos erdvės išlieka sumažintoje erdvėje, o antrasis – kiek atstatytų kaimynysčių išlieka tarp pradinių duomenų taškų. Šių metrikų reikšmės svyruoja nuo 0 iki 1, kur didesnė reikšmė reiškia geresnį struktūros išsaugojimą.

1 lentelė. Kokybės vertinimas

Metodas	Trustworthiness	Continuity
HLLE	0.7459458	0.7601654
t-SNE	0.9891435	0.9807791
MDS	0.8872287	0.9614281

Pagal gautus rezultatus (1 lentelė. Kokybės vertinimas) matyti, kad t-SNE algoritmas pasiekė aukščiausias abiejų metrikų reikšmes, todėl geriausiai išlaikė duomenų struktūros vientisumą tiek lokaliu, tiek globaliu lygmeniu. MDS metodas užėmė vidurinę poziciją – jis gana tiksliai atkūrė globalią duomenų struktūrą, tačiau buvo mažiau efektyvus išlaikant lokalius artimumus. HLLE pasirodė prasčiausiai, nes dėl jautrumo parametrai k ir duomenų mastelio pokyčiams dalis duomenų struktūrų buvo iškraipyta.

Vizualinėje analizėje taip pat pastebėta, kad t-SNE metodas formavo tris aiškiai išreikštus klasterius, atitinkančius EKG signalų klases, o MDS išlaikė bendrą pasiskirstymo simetriją, tačiau klasių ribos dalinai persidengė. HLLE metodas atskleidė tam tikras netiesines priklausomybes, tačiau dėl didesnio jautrumo mastelio pokyčiams ir išskirtims jo rezultatai buvo mažiau stabilūs.

Vertinant išskirčių elgesį, nustatyta, kad t-SNE ir MDS metodai išlaikė duomenų struktūros stabilumą net esant švelnioms ar ekstremalioms išskirtims – šie taškai daugiausia pasiskirstė klasių pakraščiuose. Tuo tarpu HLLE atvejais išskirtys darė ryškesnę įtaką – kai kurie duomenų taškai nutoldavo nuo pagrindinių grupių, todėl vizualizacijoje išryškėdavo iškraipymai.

Apibendrinant galima teigti, kad pagal tiek vizualinius, tiek kiekybinius rodiklius t-SNE metodas yra tinkamiausias EKG duomenų vizualizacijai. Jis užtikrina aukštą duomenų struktūros išlaikymo kokybę, gerą klasių atskyrimą ir mažą jautrumą išskirtims. MDS metodas gali būti naudojamas, kai siekiama išlaikyti globalų duomenų pasiskirstymą, o HLLE gali būti taikomas papildomai netiesinių ryšių analizei, tačiau reikalauja kruopštaus parametrų derinimo ir duomenų paruošimo.

7. IŠVADOS

1. Atlikus dimensijos mažinimo eksperimentus su EKG duomenimis nustatyta, kad duomenų paruošimas, ypač Min–Max normavimas, yra būtinas siekiant išvengti požymių mastelio dominavimo ir užtikrinti metodų stabilumą bei teisingą klasių atskyrimą. Nenormuotose aibėse gauti rezultatai buvo iškraipyti ir mažiau interpretuojami.
2. Pagal kokybinius rodiklius – trustworthiness ir continuity – geriausiai pasirodė t-SNE metodas ($T \approx 0.99$, $C \approx 0.98$), kuris efektyviausiai išsaugojo tiek lokalią, tiek globalią duomenų struktūrą ir suformavo aiškius trijų EKG signalų klasterius.
3. MDS metodas išlaikė globalų duomenų pasiskirstymą ir proporcingą klasių išsidėstymą dvimatėje erdvėje, ypač taikant Euklido metriką. Manhatano metrika išryškino didesnę duomenų variantiškumą ir švelnias išskirtis, tačiau sumažino klasių kompaktiškumą.
4. HLLE metodas parodė ribotą efektyvumą, nes dėl jautrumo hiperparametrui „k“ ir duomenų masteliui projekcijos tapo mažiau stabilios, o klasių ribos – neaiškios. Metodas išlieka tinkamas netiesinių ryšių paieškai, tačiau reikalauja kruopštaus parametrų derinimo.
5. Vizualinė analizė patvirtino, kad t-SNE metodas užtikrina geriausią klasių atskyrimą ir struktūros išlaikymą, MDS tinka globalios duomenų topologijos įvertinimui, o HLLE gali būti taikomas papildomai analizuojant netiesines priklausomybes tarp požymių.

PRIEDAS

```
# Būtinai paketai
library(dplyr)
library(ggplot2)
library(corrplot)
library(randomForest)
library(dimRed)      # HLLE
library(MASS)        # MDS
library(Rtsne)       # t-SNE

# Išskirčių maskė (3*IQR - Ekstremalios)
iqr_extreme_mask <- function(df, num_cols) {
  mask <- rep(FALSE, nrow(df))
  for (col in num_cols) {
    x <- df[[col]]
    q1 <- quantile(x, 0.25, na.rm = TRUE)
    q3 <- quantile(x, 0.75, na.rm = TRUE)
    iqr <- q3 - q1
    low  <- q1 - 3 * iqr
    high <- q3 + 3 * iqr
    mask <- mask | (x < low) | (x > high)
  }
  mask
}

# Švelnių išskirčių maskė (1.5*IQR)
iqr_mild_mask <- function(df, num_cols) {
  mask <- rep(FALSE, nrow(df))
  for (col in num_cols) {
    x <- df[[col]]
    q1 <- quantile(x, 0.25, na.rm = TRUE)
    q3 <- quantile(x, 0.75, na.rm = TRUE)
    iqr <- q3 - q1
    low  <- q1 - 1.5 * iqr
    high <- q3 + 1.5 * iqr
    mask <- mask | (x < low) | (x > high)
  }
  mask
}

# Min-max normavimas
normalize_min_max <- function(x) {
  max_val <- max(x, na.rm = TRUE)
  min_val <- min(x, na.rm = TRUE)
  if (max_val == min_val) return(rep(0.5, length(x)))
  (x - min_val) / (max_val - min_val)
}

# Bendroji grafikų tema ir išskirčių parametrai
OUTLIER_SHAPES <- c(
  "Neišskirtis (Įtraukta)" = 16,
  "Švelni Išskirtis" = 4,
  "Ekstremali Išskirtis" = 8
)
POINT_SIZE <- 1.5
COMMON_THEME <- theme_minimal() +
  theme(legend.position = "bottom", plot.title = element_text(face = "bold"))

setwd("~/Desktop/Data/")
# 1. Duomenų įkėlimas ir peržiūra
data <- read.csv("EKG_pupsniu_analyze.csv", sep = ";")

# Pakeičiame stulpelių pavadinimus
colnames(data) <- c(
  "RR_1_0", "RR_1_0_RR_1_1", "RR_1_1", "RR_1_1_RR_1_2", "RR_1_2",
  "RR_1_2_RR_1_3", "RR_1_3", "RR_1_3_RR_1_4", "RR_r_0", "RR_r_0_RR_r_1",
  "RR_r_1", "RR_r_1_RR_r_2", "RR_r_2", "RR_r_2_RR_r_3", "RR_r_3",
  "RR_r_3_RR_r_4", "seq_size", "signal_mean", "signal_std", "wl_side",
  "wr_side", "P_val", "Q_val", "R_val", "S_val", "T_val", "P_pos",
  "Q_pos", "R_pos", "S_pos", "T_pos", "label"
```

```

)

# Konvertuojame visus stulpelius (išskyrus 'label') į skaitinius
data <- data %>%
  mutate(across(-label, ~ as.numeric(as.character(.))))

# 2. Atrankos procesas (po 500 atsitiktinių atstovų iš kiekvienos klasės)
set.seed(42)
class_0_data <- data[data$label == 0, ]
class_1_data <- data[data$label == 1, ]
class_2_data <- data[data$label == 2, ]

sample_size <- min(500, nrow(class_0_data), nrow(class_1_data), nrow(class_2_data))
sample_0 <- class_0_data[sample(nrow(class_0_data), sample_size), ]
sample_1 <- class_1_data[sample(nrow(class_1_data), sample_size), ]
sample_2 <- class_2_data[sample(nrow(class_2_data), sample_size), ]

selected_data <- rbind(sample_0, sample_1, sample_2)
cat("Atrinkto pradinio (visų požymių) duomenų rinkinio dydis:",
paste(dim(selected_data), collapse = " x "), "\n")

# 2.5. VISŲ POŽYMIŲ AIBĖS PARUOŠIMAS
full_data_for_cleaning <- selected_data

# Nustatome visus skaitinius požymius (be label)
all_numerical_features_names <- setdiff(colnames(full_data_for_cleaning), "label")

# Konvertuojame simbolių stulpelius į skaitinius
full_data_for_cleaning$RR_r_0 <- as.numeric(full_data_for_cleaning$RR_r_0)
full_data_for_cleaning$RR_r_0_RR_r_1 <-
as.numeric(full_data_for_cleaning$RR_r_0_RR_r_1)

# Pašaliname įrašus su NA 'label'
full_data_for_cleaning <-
full_data_for_cleaning[!is.na(full_data_for_cleaning$label), ]

# 3. Praleistų reikšmių užpildymas (per klasę - medianomis)
full_data_for_cleaning <- full_data_for_cleaning %>%
  group_by(label) %>%
  mutate(across(all_numerical_features_names, ~ ifelse(is.na(.), median(., na.rm =
TRUE), .))) %>%
  ungroup()

# 5. Išskirčių žymėjimas (NE šalinimas)
mask_extreme_full <- iqr_extreme_mask(full_data_for_cleaning,
all_numerical_features_names)
mask_mild_full <- iqr_mild_mask(full_data_for_cleaning,
all_numerical_features_names)

# Sukuriame naują kintamąjį - trijų lygių faktorių
full_data_for_cleaning$sis_mild_outlier <- "Neišskirtis (Įtraukta)"
full_data_for_cleaning$sis_mild_outlier[mask_mild_full] <- "Švelni Išskirtis"
full_data_for_cleaning$sis_mild_outlier[mask_extreme_full] <- "Ekstremali Išskirtis"

full_data_for_cleaning$sis_mild_outlier <- factor(
  full_data_for_cleaning$sis_mild_outlier,
  levels = c("Neišskirtis (Įtraukta)", "Švelni Išskirtis", "Ekstremali Išskirtis")
)

cat("\nEkstremalių įrašų (3*IQR):", sum(mask_extreme_full), "\n")
cat("Švelnių įrašų (1.5*IQR):", sum(mask_mild_full), "\n")

# Toliau naudojam visą duomenų aibę
full_data_no_outliers <- full_data_for_cleaning

# --- Duomenų aprašomoji statistika ---
cat("\n-----\n")
cat("DUOMENŲ AIBĖS APRAŠOMOJI STATISTIKA\n")
cat("-----\n\n")

str(data)

```

```

summary(data)

# 6. Min-Max normavimas (viso rinkinio)
full_norm_df <- as.data.frame(lapply(full_data_no_outliers[,
all_numerical_features_names], normalize_min_max))
full_norm_df$label <- full_data_no_outliers$label
full_norm_df$sis_mild_outlier <- full_data_no_outliers$sis_mild_outlier

# --- DM VIZUALIZACIJA: VISŲ POŽYMIŲ AIBĖ ---
X_full_unnorm <- as.matrix(full_data_no_outliers[, all_numerical_features_names])
X_full_norm <- as.matrix(full_norm_df[, all_numerical_features_names])
y_full <- as.factor(full_data_no_outliers$label)

cat("\n-----\n")
cat("DM VIZUALIZACIJA: VISŲ POŽYMIŲ AIBĖ\n")
cat("-----\n\n")

## HLLE - VISŲ
hlle_full_norm <- embed(dimRedData(as.data.frame(X_full_norm), meta = list(labels =
y_full)),
                        "HLLE", knn = 30, ndim = 2)
hlle_full_df_norm <- data.frame(
  HLLE1 = hlle_full_norm@data@data[,1],
  HLLE2 = hlle_full_norm@data@data[,2],
  label = y_full,
  sis_mild_outlier = full_data_no_outliers$sis_mild_outlier
)
ggplot(hlle_full_df_norm, aes(HLLE1, HLLE2, color = label, shape =
sis_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "HLLE - VISŲ požymių aibė (Normuota)", subtitle = "k = 30") +
COMMON_THEME

hlle_full_unnorm <- embed(dimRedData(as.data.frame(X_full_unnorm), meta =
list(labels = y_full)),
                        "HLLE", knn = 30, ndim = 2)
hlle_full_df_unnorm <- data.frame(
  HLLE1 = hlle_full_unnorm@data@data[,1],
  HLLE2 = hlle_full_unnorm@data@data[,2],
  label = y_full,
  sis_mild_outlier = full_data_no_outliers$sis_mild_outlier
)
ggplot(hlle_full_df_unnorm, aes(HLLE1, HLLE2, color = label, shape =
sis_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "HLLE - VISŲ požymių aibė (Nenormuota)", subtitle = "k = 30") +
COMMON_THEME

## t-SNE - VISŲ
set.seed(42)
tsne_full_norm <- Rtsne(X_full_norm, dims = 2, perplexity = 30, max_iter = 1000,
                        verbose = FALSE, check_duplicates = FALSE)
tsne_full_df_norm <- data.frame(
  tSNE1 = tsne_full_norm$Y[,1], tSNE2 = tsne_full_norm$Y[,2],
  label = y_full,
  sis_mild_outlier = full_data_no_outliers$sis_mild_outlier
)
ggplot(tsne_full_df_norm, aes(tSNE1, tSNE2, color = label, shape =
sis_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "t-SNE - VISŲ požymių aibė (Normuota)", subtitle = "perplexity =
30") + COMMON_THEME

set.seed(42)
tsne_full_unnorm <- Rtsne(X_full_unnorm, dims = 2, perplexity = 30, max_iter =
1000,
                        verbose = FALSE, check_duplicates = FALSE)
tsne_full_df_unnorm <- data.frame(
  tSNE1 = tsne_full_unnorm$Y[,1], tSNE2 = tsne_full_unnorm$Y[,2],

```

```

    label = y_full,
    is_mild_outlier = full_data_no_outliers$sis_mild_outlier
  )
ggplot(tsne_full_df_unnorm, aes(tSNE1, tSNE2, color = label, shape =
is_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "t-SNE - VISŲ požymių aibė (Nenormuota)", subtitle = "perplexity =
30") + COMMON_THEME

## MDS (metrinis, Euclidean) - VISŲ
dist_full_norm <- dist(X_full_norm, method = "euclidean")
mds_full_norm <- cmdscale(dist_full_norm, k = 2)
mds_full_df_norm <- data.frame(
  MDS1 = mds_full_norm[,1], MDS2 = mds_full_norm[,2],
  label = y_full,
  is_mild_outlier = full_data_no_outliers$sis_mild_outlier
)
ggplot(mds_full_df_norm, aes(MDS1, MDS2, color = label, shape = is_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "MDS - VISŲ požymių (Normuota)", subtitle = "Euclidean") +
COMMON_THEME

dist_full_unnorm <- dist(X_full_unnorm, method = "euclidean")
mds_full_unnorm <- cmdscale(dist_full_unnorm, k = 2)
mds_full_df_unnorm <- data.frame(
  MDS1 = mds_full_unnorm[,1], MDS2 = mds_full_unnorm[,2],
  label = y_full,
  is_mild_outlier = full_data_no_outliers$sis_mild_outlier
)
ggplot(mds_full_df_unnorm, aes(MDS1, MDS2, color = label, shape = is_mild_outlier))
+
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "MDS - VISŲ požymių (Nenormuota)", subtitle = "Euclidean") +
COMMON_THEME

# --- 6 POŽYMIŲ ANALIZĖ (naudojant tą pačią išvalytą aibę) ---
cat("\n-----\n")
cat("DM VIZUALIZACIJA: ATRINKTŲ 6 POŽYMIŲ AIBĖ\n")
cat("-----\n\n")

selected_features_6 <- c("RR_l_0", "RR_r_0", "RR_l_0_RR_l_1", "RR_r_0_RR_r_1",
"signal_mean", "signal_std", "label", "is_mild_outlier")
atrinkti_no_outliers <- full_data_no_outliers[, selected_features_6] # nenormuota
atrinkti_min_max <- full_norm_df[, selected_features_6] # normuota

num_cols_to_check <- setdiff(selected_features_6, c("label", "is_mild_outlier"))
X_norm <- as.matrix(atrinkti_min_max[, num_cols_to_check])
X_unnorm <- as.matrix(atrinkti_no_outliers[, num_cols_to_check])
y <- as.factor(atrinkti_no_outliers$label)

# Pavyzdinis boxplot prieš/po
par(mfrow = c(1,2))
boxplot(selected_data$signal_std, main = "signal_std prieš 3*IQR", col = "tomato",
outline = TRUE)
boxplot(atrinkti_no_outliers$signal_std, main = "signal_std po 3*IQR", col =
"skyblue", outline = TRUE)

## HLLE - 6 požymių
hlle_norm <- embed(dimRedData(as.data.frame(X_norm), meta = list(labels = y)),
"HLLE", knn = 30, ndim = 2)
hlle_norm_df <- data.frame(
  HLLE1 = hlle_norm@data@data[,1],
  HLLE2 = hlle_norm@data@data[,2],
  label = y,
  is_mild_outlier = atrinkti_min_max$sis_mild_outlier
)
ggplot(hlle_norm_df, aes(HLLE1, HLLE2, color = label, shape = is_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +

```

```

labs(title = "HLE - 6 požymiai (Normuota)", subtitle = "k = 30") + COMMON_THEME

hle_unnorm <- embed(dimRedData(as.data.frame(X_unnorm), meta = list(labels = y)),
  "HLE", knn = 30, ndim = 2)
hle_unnorm_df <- data.frame(
  HLE1 = hle_unnorm@data@data[,1],
  HLE2 = hle_unnorm@data@data[,2],
  label = y,
  is_mild_outlier = atrinkti_no_outliers$sis_mild_outlier
)
ggplot(hle_unnorm_df, aes(HLE1, HLE2, color = label, shape = is_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "HLE - 6 požymiai (Nenormuota)", subtitle = "k = 30") +
COMMON_THEME

# HLE su skirtingais k (normuotoje erdvėje)
for (k in c(20, 30, 40)) {
  hle_test <- embed(dimRedData(as.data.frame(X_norm), meta = list(labels = y)),
    "HLE", knn = k, ndim = 2)
  df_test <- data.frame(
    HLE1 = hle_test@data@data[,1],
    HLE2 = hle_test@data@data[,2],
    label = y,
    is_mild_outlier = atrinkti_min_max$sis_mild_outlier
  )
  p <- ggplot(df_test, aes(HLE1, HLE2, color = label, shape = is_mild_outlier)) +
    geom_point(alpha = 0.8, size = POINT_SIZE) +
    scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
    labs(title = paste("HLE - k =", k, "(6 požymiai)")) + COMMON_THEME
  print(p)
}

## t-SNE - 6 požymių
set.seed(42)
tsne_norm <- Rtsne(X_norm, dims = 2, perplexity = 30, max_iter = 1000,
  verbose = FALSE, check_duplicates = FALSE)
tsne_norm_df <- data.frame(
  tSNE1 = tsne_norm$Y[,1], tSNE2 = tsne_norm$Y[,2],
  label = y,
  is_mild_outlier = atrinkti_min_max$sis_mild_outlier
)
ggplot(tsne_norm_df, aes(tSNE1, tSNE2, color = label, shape = is_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "t-SNE - 6 požymiai (Normuota)", subtitle = "perplexity = 30") +
COMMON_THEME

set.seed(42)
tsne_unnorm <- Rtsne(X_unnorm, dims = 2, perplexity = 30, max_iter = 1000,
  verbose = FALSE, check_duplicates = FALSE)
tsne_unnorm_df <- data.frame(
  tSNE1 = tsne_unnorm$Y[,1], tSNE2 = tsne_unnorm$Y[,2],
  label = y,
  is_mild_outlier = atrinkti_no_outliers$sis_mild_outlier
)
ggplot(tsne_unnorm_df, aes(tSNE1, tSNE2, color = label, shape = is_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "t-SNE - 6 požymiai (Nenormuota)", subtitle = "perplexity = 30") +
COMMON_THEME

# --- Papildoma t-SNE analizė su learning rate ir metrika ---
for (lr in c(10, 100, 500)) {
  for (metric in c("euclidean", "manhattan")) {
    set.seed(42)

    # Skaičiuojame atstumų matricą pagal pasirinktą metriką
    dist_matrix <- dist(X_norm, method = metric)

    # Paduodame ją t-SNE kaip atstumų matricą
    tsne_test <- Rtsne(as.matrix(dist_matrix), is_distance = TRUE,

```

```

        dims = 2, perplexity = 30, eta = lr, verbose = FALSE)

# Sudarome rezultatų duomenų rėmelį
df_tsne <- data.frame(
  tSNE1 = tsne_test$Y[,1],
  tSNE2 = tsne_test$Y[,2],
  label = y,
  is_mild_outlier = atrinkti_min_max$sis_mild_outlier
)

# Braižome rezultata
g <- ggplot(df_tsne, aes(tSNE1, tSNE2, color = label, shape = is_mild_outlier))
+
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = paste("t-SNE - metrika:", metric, ", learning rate:", lr)) +
COMMON_THEME

  print(g)
}
}

# t-SNE su skirtingais perplexity (normuota)
for (p in c(5, 30, 50)) {
  set.seed(42)
  tsne_test <- Rtsne(X_norm, dims = 2, perplexity = p, verbose = FALSE,
check_duplicates = FALSE)
  df_test <- data.frame(
    tSNE1 = tsne_test$Y[,1], tSNE2 = tsne_test$Y[,2],
    label = y,
    is_mild_outlier = atrinkti_min_max$sis_mild_outlier
  )
  g <- ggplot(df_test, aes(tSNE1, tSNE2, color = label, shape = is_mild_outlier)) +
    geom_point(alpha = 0.8, size = POINT_SIZE) +
    scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
    labs(title = paste("t-SNE - perplexity =", p, "(6 požymiai)")) + COMMON_THEME
  print(g)
}

## MDS (metrinis) - 6 požymių
dist_norm <- dist(X_norm, method = "euclidean")
mds_norm <- cmdscale(dist_norm, k = 2)
mds_norm_df <- data.frame(
  MDS1 = mds_norm[,1], MDS2 = mds_norm[,2],
  label = y,
  is_mild_outlier = atrinkti_min_max$sis_mild_outlier
)
ggplot(mds_norm_df, aes(MDS1, MDS2, color = label, shape = is_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "MDS - 6 požymiai (Normuota)", subtitle = "Euclidean") +
COMMON_THEME

dist_unnorm <- dist(X_unnorm, method = "euclidean")
mds_unnorm <- cmdscale(dist_unnorm, k = 2)
mds_unnorm_df <- data.frame(
  MDS1 = mds_unnorm[,1], MDS2 = mds_unnorm[,2],
  label = y,
  is_mild_outlier = atrinkti_no_outliers$sis_mild_outlier
)
ggplot(mds_unnorm_df, aes(MDS1, MDS2, color = label, shape = is_mild_outlier)) +
  geom_point(alpha = 0.8, size = POINT_SIZE) +
  scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
  labs(title = "MDS - 6 požymiai (Nenormuota)", subtitle = "Euclidean") +
COMMON_THEME

# Metrikų palyginimas (normuota)
for (dist_type in c("euclidean", "manhattan")) {
  dist_m <- dist(X_norm, method = dist_type)
  mds_m <- cmdscale(dist_m, k = 2)
  df_m <- data.frame(
    MDS1 = mds_m[,1], MDS2 = mds_m[,2],

```

```

    label = y,
    is_mild_outlier = atrinkti_min_max$is_mild_outlier
  )
  p <- ggplot(df_m, aes(MDS1, MDS2, color = label, shape = is_mild_outlier)) +
    geom_point(alpha = 0.8, size = POINT_SIZE) +
    scale_shape_manual(values = OUTLIER_SHAPES, name = "Išskirties Tipas") +
    labs(title = paste("MDS -", dist_type, "(6 požymiai)") + COMMON_THEME
  )
  print(p)
}

# --- KOKYBĖS VERTINIMAS: HLE, t-SNE, MDS ---

# NUSTATYKITE TEISINGĄ K PARAMETRĄ
k_param <- 12
n <- nrow(X_norm) # Bendras stebėjimų skaičius

# HLE - skaičiuojama rankiniu būdu
hle_Y <- hle_norm@data@data

# --- FUNKCIJA METRIKOMS SKAIČIUOTI TIK SU BAZINE R LOGIKA ---
calculate_metrics_exact <- function(X_orig, X_embedded, k) {
  # 1. Atstumo ir rangų matricos
  D_orig <- as.matrix(dist(X_orig))
  D_emb <- as.matrix(dist(X_embedded))

  R_orig <- apply(D_orig, 1, rank, ties.method = "first")
  R_emb <- apply(D_emb, 1, rank, ties.method = "first")

  n <- nrow(X_orig)

  # 2. Trustworthiness ir Continuity sumos
  trust_sum <- 0
  cont_sum <- 0

  for (i in 1:n) {
    # kaimynų rinkiniai
    orig_neighbors <- order(D_orig[i, ])[2:(k+1)]
    emb_neighbors <- order(D_emb[i, ])[2:(k+1)]

    # Trustworthiness: j embedding arti, bet ne originaliai
    Ui <- setdiff(emb_neighbors, orig_neighbors)
    if (length(Ui) > 0) {
      trust_sum <- trust_sum + sum(R_orig[i, Ui] - k)
    }

    # Continuity: j originaliai arti, bet ne embedding
    Vi <- setdiff(orig_neighbors, emb_neighbors)
    if (length(Vi) > 0) {
      cont_sum <- cont_sum + sum(R_emb[i, Vi] - k)
    }
  }

  # 3. Normalizavimo faktorius
  normalizer <- n * k * (2 * n - 3 * k - 1)

  # 4. Galutinės formulės
  trust <- 1 - (2 / normalizer) * trust_sum
  cont <- 1 - (2 / normalizer) * cont_sum

  return(list(trustworthiness = trust, continuity = cont))
}

# HLE
metrics_hle <- calculate_metrics_exact(X_norm, hle_Y, k = k_param)
trust_hle <- metrics_hle$trustworthiness
cont_hle <- metrics_hle$continuity

# t-SNE
metrics_tsne <- calculate_metrics_exact(X_norm, tsne_norm$Y, k = k_param)
trust_tsne <- metrics_tsne$trustworthiness
cont_tsne <- metrics_tsne$continuity

```

```
# MDS
metrics_mds <- calculate_metrics_exact(X_norm, mds_norm_df[,1:2], k = k_param)
trust_mds <- metrics_mds$trustworthiness
cont_mds <- metrics_mds$continuity

# --- Rezultatų suvestinė ---
kokybes_vertinimas <- data.frame(
  Metodas = c("HLL", "t-SNE", "MDS"),
  Trustworthiness = c(trust_hlle, trust_tsne, trust_mds),
  Continuity = c(cont_hlle, cont_tsne, cont_mds)
)

print(kokybes_vertinimas)
```