



Vizualizavimas

Dėstytojai:

prof. habil. dr. Gintautas Dzemyda

gintautas.dzemyda@mif.vu.lt

dr. Jolita Bernatavičienė

jolita.bernatavicienne@mif.vu.lt

Vilniaus universitetas

Duomenų mokslo ir skaitmeninių technologijų institutas

Akademijos g. 4

www.datascience.lt


www.mii.lt


Agora University of Oradea


The Blue Aula



**2020 || 8TH INTERNATIONAL CONFERENCE ON COMPUTERS
COMMUNICATIONS AND CONTROL (ICCCC)**







Šiuolaikiškomis technologijomis galima gauti ir saugoti didelius duomenų kiekius ir srautus.

Tačiau tebelieka esminė problema – kaip tuos duomenis suvokti ir interpretuoti, o taip pat priimti geriausius sprendimus žinių, gautų iš šių duomenų, pagrindu.

Dažnai labai svarbu gauti kuo daugiau naudingų žinių, suprasti duomenis, atskirti svarbią informaciją nuo menkavertės.

Suvokti duomenis yra nelengvas uždavinys, ypač kai jie yra *daugiamačiai*, t. y. kai nurodo sudėtingą objektą ar reiškinį, apibūdinamą daugeliu parametrų (požymių, savybių, rodiklių, ypatybių), kurie gali būti ne tik skaitiniai, bet loginiai, tekstiniai ir kt.

Dažnai iškyla būtinybė nustatyti ir giliau pažinti tokių duomenų struktūrą: susidariusias grupes (klasterius, *cluster*), itin išsiskiriančius objektus (taškus atsiskyrėlius, *outliers*), objektų tarpusavio panašumą ar skirtingumą ir pan.

Kuo didesnės apimties duomenys (didesnis objektų arba matmenų skaičius), tuo sunkiau iš duomenų lentelės suvokti objektų visumos ypatybes.

Tokių duomenų analizė reikalauja intensyvių tyrimų. Tai gana sudėtingi uždaviniai. Spręsdamas juos žmogus gali įsigilinti į duomenis ir daryti išvadas.

Tam tikslui yra naudojami įvairūs duomenų analizės metodai: klasifikavimo, klasterizavimo, vizualizavimo ir kt.

Šiuo metu duomenų analizė yra labai aktuali įvairiose veiklos srityse: versle, ekonomikoje, medicinoje, sociologijoje ir kt.

Labai svarbu duomenis pateikti žmogui suprantama forma, padedančia geriau juos suvokti: nustatyti struktūrą, tarpusavio ryšius, susidariusias grupes, prognozuojamus įverčius ir pan.

Vizualizavimas – tai grafinis informacijos pateikimas.

Pagrindinė vizualizavimo idėja – duomenis pateikti tokia forma, kuri leistų tyrėjui juos suprasti, daryti išvadas ir tiesioginę įtaką tolesniam jų srautui.

Vizualizavimas leidžia geriau suvokti sudėtingas duomenų aibes, gali padėti nustatyti dominančius jos poaibius.

Vizualią informaciją žmogus pajėgus suvokti daug greičiau negu tekstinę, ji palengvina naujų žinių atradimą.

Daugiamačių duomenų pavyzdys (vėžio duomenys)

	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	C
X_1	5	1	1	1	2	1	3	1	1	b
X_2	5	4	4	5	7	10	3	2	1	b
X_3	3	1	1	1	2	2	3	1	1	b
X_4	6	8	8	1	3	4	3	7	1	b
X_5	4	1	1	3	2	1	3	1	1	b
X_6	1	1	1	1	2	10	3	1	1	b
X_7	2	1	2	1	2	1	3	1	1	b
X_8	2	1	1	1	2	1	1	1	5	b
X_9	4	2	1	1	2	1	2	1	1	b
...	...	...	...	...	...	...	...	...	...	...
X_{460}	8	10	10	8	7	10	9	7	1	m
X_{461}	5	3	3	3	2	3	4	4	1	m
X_{462}	8	7	5	10	7	9	5	5	4	m
X_{463}	7	4	6	4	6	1	4	3	1	m
X_{464}	10	7	7	6	4	10	4	1	2	m
X_{465}	7	3	2	10	5	10	5	4	4	m
X_{466}	10	5	5	3	6	7	7	10	1	m
X_{467}	5	2	3	4	2	7	3	6	1	m
...	...	...	...	...	...	...	...	...	...	...


*University of Wisconsin,
Clinical Sciences Center*

x_1 – clump thickness,
 x_2 – uniformity of cell size,
 x_3 – uniformity of cell shape,
 x_4 – marginal adhesion,
 x_5 – single epithelial cell size,
 x_6 – bare nuclei,
 x_7 – bland chromatin,
 x_8 – normal nucleoli,
 x_9 – mitoses,


C – class (**b**enign, **m**alignant)
 (Nepiktybinis. Piktybinis)

Ankstyvoji diagnostika

Ankstyvoji diagnostika




Ankstyvoji diagnostika



Naujas pacientas 1
(nepiktybinis)


Ankstyvoji diagnostika



Naujas pacientas 2
(būtini papildomi
tyrimai)


Naujas pacientas 1
(nepiktybinis)

Ankstyvoji diagnostika



Ankstyvoji diagnostika

- Nepiktybinio naviko atvejai yra panašūs.
- Sunku prognozuoti pacientės būseną, kai atvejis tampa piktybiniu.



Apibrėžkime pagrindines sąvokas ir žymėjimus.

Nagrinėsime daugiamačius duomenis, jų vizualiosios analizės problemas ir metodus.

Čia susiduriame su dviem pagrindinėmis sąvokomis. Tai *objektas* ir *parametras*.

Sąvoka *objektas* gali apimti įvairius dalykus: žmones, įrenginius, gamybos produktus, augalus, gamtos reiškinius ir kt.

Objektai (*objects*), sudarantys konkrečią analizuojamų objektų aibę, yra apibūdinami bendrais parametrais (*features, parameters, attributes*), dar dažnai vadinamais požymiais, savybėmis, rodikliais, ypatybėmis.

Objektų tokioje aibėje skaičius m yra baigtinis, tačiau bendru atveju gali būti ir labai didelis.

Tam tikras visų parametru reikšmių rinkinys nusako vieną konkretų analizuojamos aibės objektą

$$X_i = (x_{i1}, x_{i2}, \dots, x_{in}) \quad i \in \{1, \dots, m\}$$

Čia n yra parametru skaičius, i yra objekto eilės numeris. Parametru skaičius n dar yra vadinamas duomenų matmenų skaičiumi.

Kai objektą $X_i = (x_{i1}, x_{i2}, \dots, x_{in})$ apibūdina daugiau nei vienas parametras, duomenys (objektai) yra daugiamačiai.

Nagrinėsime pakankamai bendrą duomenų analizės atvejį, kai parametrai įgyja tam tikras skaitines reikšmes. Todėl analizuojamų duomenų aibė yra matrica

$$X = \{X_1, X_2, \dots, X_m\} = \{x_{ij}, \quad i = 1, \dots, m, \quad j = 1, \dots, n\}$$

kurios i -oji eilutė yra vektorius

$$X_i \in R^n \quad X_i = (x_{i1}, x_{i2}, \dots, x_{in}) \quad i \in \{1, \dots, m\}$$

m – analizuojamų objektų (vektorių) skaičius.

Būna atvejų, kai atskirą objektą nusakančio parametrų skaitinių reikšmių rinkinio neturime, jo negalima gauti, t. y. negalime suformuoti skaitinių duomenų matricos X , tačiau galime skaitiškai įvertinti artimumus (*proximity*) tarp objektų porų – panašumus (*similarity*) ar skirtingumus (*dissimilarity*).

Šiuo atveju duomenų matmenų skaičius n gali būti ir nežinomas. Taip dažnai būna, pavyzdžiui, psichologiniuose tyrimuose.

Tuo atveju analizė atliekama naudojantis artimumų (pavyzdžiui, skirtingumų) matrica

$$\Delta = \{\delta_{ij}, i, j = 1, \dots, m\},$$

čia δ_{ij} yra objektų X_i ir X_j artimumo įvertis.

Artimumų matricą galima gauti ir iš matricos X , pritaikius kokią nors artimumo metriką.

Fišerio irisų duomenys, kurie kartais vadinami tiesiog irisais arba irisų duomenimis, yra vieni iš klasikinių testinių duomenų, naudojamų daugiamatčių duomenų analizei.

Išmatuoti keturi 150-ies irisų (vilkdalgių) žiedų parametrai ($m=150$):

- taurėlapių ilgiai (sepal length)
- taurėlapių pločiai (sepal width)
- vainiklapių ilgiai (petal length)
- vainiklapių pločiai (petal width)

Matuotos trijų veislių gėlės:

- Iris Setosa (I klasė)
- Iris Versicolor (II klasė)
- Iris Virginica (III klasė)

Sudaryti 4-matčiai vektoriai ($n=4$)

Automobilių, pagamintų 1970–1982 metais JAV, Europoje ir Japonijoje, duomenys (398 automobiliai, $m=398$). Trijų regionų automobilius apibūdina devyni parametrai ($n=9$):


- degalų sąnaudos (mpg);
- cilindų skaičius (cylinders);
- variklio darbo tūris (displacement);
- arklio jėgų kiekis (horsepower);
- svoris (weight);
- greitis (accelerator);
- modelio pagaminimo metai (model years);
- kilmės regionas (origin);
- modelis (name).

Paskutiniai du parametrai nėra skaitiniai, todėl paprastai vizualizavimo procese tiesiogiai nėra naudojami – jie nusako objektų priklausomybę skirtingoms klasėms, pavyzdžiui, skirtingi kilmės regionai ar modeliai. Dažniausiai analizuojami 7-mačiai vektoriai ($n=7$).

Paprasčiausi vizualizavimo būdai


Taškiniam grafike duomenys vaizduojami taškais (tiksliau – ženkleliais) ir išrinktoms x-ašyje savybėms atitinka y-ašies duomenų reikšmės.

Taškiniam grafike dažnai braižoma trendo linija (dar vadinama krypties linija), kuri skirta parodyti ryšį tarp duomenų, atkreipti dėmesį į esamų duomenų tendencijas arba ateities duomenų prognozes.




Paprasčiausi vizualizavimo būdai

Stulpelinė diagrama (angl. bar chart). Galima braižyti duomenų, išdėstytų lentelės stulpeliuose arba eilutėse, stulpelinę diagramą. Stulpelinės diagramos kategorijos paprastai vaizduojamos palei horizontaliąją (kategorijos) ašį, o reikšmės – palei vertikaliąją (reikšmių)




Paprasčiausi vizualizavimo būdai

Skritulinė diagrama (pie chart) vaizduoja vienos duomenų sekos elementų dydį proporcingai elementų sumai. Skritulinėje diagramoje duomenų taškai rodomi kaip viso skritulio procentinės dalys (visas skritulys yra 100 procentų).



Paprasciausi vizualizavimo būdai


Burbulinė diagrama (angl. bubble chart) yra grafiko ir diagramos mišinys, kur ant dviejų ašių paskirstyti nurodytų reikšmių taškai. Tik duomenų taškai čia pakeisti burbulais (rutuliais), kurie nesujungiami tarpusavyje, tačiau burbulų tūris išreiškia papildomą duomenų matmenį.



Paprasčiausi vizualizavimo būdai

Dendrograma (angl. dendrogram), naudojama siekiant grafiškai parodyti atskirų objektų ar grupių artumą. Tai medžio pavidalo diagrama, kur linijos sujungiamos kai reikšmių parametrai sutampa. Kuo ankščiau linijos sujungiamos, tuo reikšmės artimesnės viena kitai.


Paveiksle matome dendrogramą, kurioje analizuojamos Eurovizijos dainų konkurse dalyvaujančių šalių balsavimo tendencijos 1992 – 2003 metų periode. Aukšta koreliacija įrodo, kad egzistuoja balsavimo grupės



Paprasčiausi vizualizavimo būdai

Žiedinė ryšių diagrama (angl. circos diagram) – tai žiedo formos diagrama su pažymėtomis reikšmėmis, kurioje duomenų ryšiai parodomi sujungtomis linijomis žiedo viduje.

Vieno genomo viduje esančių chromosomų ryšių vizualizavimas:




Visualizing Complex Data and Relations


- Visualizing non-numerical data: text and social networks
- Tag cloud: visualizing user-generated tags (žymės)
 - The importance of tag is represented by font size/color
 - Besides text data, there are also methods to visualize relationships, such as visualizing social networks




Newsmap: Google News Stories in 2005

Daugiamačių duomenų vizualizavimas









Tiesioginio vizualizavimo metodai

Taškiniai grafikai (Scatter Plots)


Taškiniai grafikai (scatter plots) yra vienas dažniausiai naudojamų duomenų pateikimo plokštumoje arba trimatėje erdvėje būdų. Taškai (vektoriai) atvaizduojami įprastu (x, y) arba (x, y, z) format.

Dažniausiai šiuo būdu atvaizduojami dvimačiai ($n=2$) arba trimačiai ($n=3$) taškai.



Landscapes

Used by permission of B. Wright, Visible Decisions Inc.




news articles
visualized as
a landscape

- Visualization of the data as perspective landscape
- The data needs to be transformed into a (possibly artificial) 2D spatial representation which preserves the characteristics of the data


Taškinių grafikų matrica (Scatterplot Matrices)

Naudojant taškinių grafikų matricą, taškinius grafikus galima taikyti daugiau nei trijų matmenų duomenims vizualizuoti. Tokioje matricoje atvaizduojamos visos galimos n -mačius duomenis apibūdinančių parametų poros.



Taškinių grafikų matrica (Scatterplot Matrices)

Used by permission of M. Ward, Worcester Polytechnic Institute



Linijiniai grafikai (*line graphs*) yra naudojami vieno kintamojo funkcijoms vaizduoti. Jie dažniausiai taikomi dvimačiams duomenims vizualizuoti.

Pavyzdyje pirmiausia duomenys surūšiuoti pagal automobilių kilmės regioną (JAV, Europa, Japonija), kiekvienos kilmės regiono grupėje – pagal pagaminimo metus.


Ašyje x atidėti analizuojamų objektų (automobilių) eilės numeriai duomenų sekoje.

Analizuojamus duomenis apibūdinančių parametrų reikšmės gali būti iš skirtingų intervalų, todėl prieš vizualizuojant patartina duomenis sunormuoti.

Ašyje y pavaizduotos sunormuotos skirtingų parametrų reikšmės.

Grafikų linijos storis priklauso nuo automobilio kilmės regiono.


Iš paveikslo matyti automobilius apibūdinančių parametrų reikšmių kitimas priklausomai nuo pagaminimo metų ir kilmės. Pavyzdžiui, automobilių, pagamintų JAV, vidutinis cilindų skaičius yra didesnis nei pagamintų Japonijoje ar Europoje.




Lygiagrečiosios koordinatės

Dekarto koordinačių sistemoje visos ašys yra statmenos viena kitai. Lygiagrečiųjų koordinačių sistemoje visos ašys yra lygiagrečios viena su kita ir išdėstytos vienodu atstumu.

Lygiagrečiosiose koordinatėse galima vaizduoti taškus, kurių matmenų skaičius didesnis nei trys.



Parallel Coordinates of a Data Set




Hierarchinės lygiagrečiosios koordinatės

Viena lygiagrečiųjų koordinačių metodo modifikacija yra hierarchinių lygiagrečiųjų koordinačių metodas.

Kai vizualizuojama didelė duomenų aibė hierarchinių lygiagrečiųjų koordinačių metodu, sumažėja persidengiančių linijų, gaunamų lygiagrečiųjų koordinačių metodu.

Duomenys hierarchinėse lygiagrečiosiose koordinatėse pavaizduojami šiuo būdu:

- iš pradžių analizuojami duomenys yra suklasterizuojami į atskirus klasterius, naudojantis vienu iš klasterizavimo metodų;
- duomenys pavaizduojami lygiagrečiosiose koordinatėse, išryškinami klasterių centrai; klasterių narių spalvos intensyvumas priklauso nuo to, kaip arti jie yra iki klasterio centro; skirtingi klasteriai vaizduojami skirtingomis spalvomis.



Černovo veidai

Vizualizuojamas objektas vaizduojamas stilizuotu veidu. Kiekvienas iš objektą nusakančių parametrų apibūdina tam tikros veido dalies dydį, padėtį ar formą, pavyzdžiui, vienas parametras – burnos plotį, kitas – akių formą ir pan.



I



I



I



I



I



II



II



II



II



II



III



III



III



III



III

Taurėlapių ilgių reikšmės atitinka veido dydį, taurėlapių pločių – kaktos formą, vainiklapių ilgių – smakro formą, vainiklapių pločių – nosies ilgį.

Kaip matome, veidai, atitinkantys I klasę (*Setosa*), labai skiriasi nuo veidų, atitinkančių II ir III klases (*Versicolor* ir *Virginica*). Veidai, atitinkantys II klasę (*Versicolor*), mažai skiriasi nuo veidų, atitinkančių III klasę (*Virginica*). Čia naudotasi *Matlab* sistema (<http://www.mathworks.com>).



I



I



I



I



I



II



II



II



II



II



III



III



III



III



III

Žvaigždės

Daugiamačiams duomenims vizualizuoti gali būti naudojamas žvaigždžių metodas (star glyphs).


Kiekvienas vizualizuojamas objektas vaizduojamas stilizuota žvaigžde. Iš vieno taško nubraižoma tiek spindulių, kiek yra objektą apibūdinančių parametrų.

Kampai tarp spindulių turi būti vienodi.


Spindulio ilgis priklauso nuo jį atitinkančio parametro reikšmės.

Išoriniai spindulių galai yra sujungiami linijomis.

I klasės irisus (Setosa) atitinkančios žvaigždės yra mažesnės už kitų dviejų (II ir III) klasių. Didžiausios žvaigždės atitinka III klasę (Virginica). Naudotasi Matlab sistema (<http://www.mathworks.com>).




Spider chart, Radar chart – Žvaigždžių variacija



Laying Out Pixels in Circle Segments


- To save space and show the connections among multiple dimensions, space filling is often done in a circle segment




Representing a data record in circle segment

Pixel-Oriented Visualization Techniques


- For a data set of m dimensions, create m windows on the screen, one for each dimension
- The m dimension values of a record are mapped to m pixels at the corresponding positions in the windows
- The colors of the pixels reflect the corresponding values
- Inside a window, the data values are arranged in some global order shared by all windows. The global order may be obtained by sorting all data records in a way that's meaningful for the task at hand.




(a) Income



(b) Credit Limit



(c) transaction volume



(d) age

Projekcijos metodai

Analizuojant daugiamačius objektus, kuriuos apibūdina n parametrų, norima vizualiai įvertinti jų išsidėstymą n -matėje erdvėje.

Kai $n > 3$, tiesiogiai pamatyti šių taškų neįmanoma.


Tačiau yra galimybė rasti jų projekciją į dvimatę ar trimatę erdvę, t. y. sumažinti matmenų skaičių iki mums įprasto!

Pavyzdys


Dešinėje ir viršuje padėti ekranai. Įsivaizduokime, kad kitoje pusėje šviečia ryški šviesa. Ant ekranų matomi duomenų taškų šešėliai.

Linijos sujungia taškus su jų projekcijomis. Iš a paveikslo matyti, kad dvimatėje projekcijoje išlieka du klasteriai, tačiau b paveiksle jokių klasterių negalima įžvelgti.

a)



b)



Projekcijos metodai gali būti naudojami ir daugiamatiams duomenims vizualizuoti, kai pasirinktas pakankamai mažas projekcinės erdvės R^d matmenų skaičius ($d = 1, d = 2$ arba $d = 3$).

Erdvė R^d dar vadinama *vaizdo erdve*, nes dažnai jos elementus galima stebėti vizualiai.

Tarkime, kad analizuojamų duomenų aibė yra matrica

$$X = \{X_1, X_2, \dots, X_m\} = \{x_{ij}, i = 1, \dots, m, j = 1, \dots, n\},$$

i -oji eilutė yra vektorius $X_i \in R^n$, čia $X_i = (x_{i1}, x_{i2}, \dots, x_{in})$, $i \in \{1, \dots, m\}$, x_{ij} yra duomenų i -ojo taško X_i j -oji komponentė, atitinkanti j -ąjį parametą, n – vektoriaus X_i komponentių skaičius, m – analizuojamų objektų (vektorių) skaičius.

Reikia rasti vektoriaus $X_i = (x_{i1}, x_{i2}, \dots, x_{in})$ transformaciją $Y_i = (y_{i1}, y_{i2}, \dots, y_{id})$ mažesnio skaičiaus matmenų *projekcinėje*, arba *vaizdo*, erdvėje R^d , $d < n$.

Jeigu projekcijos metodo tikslas – vizualizuoti duomenis, tai $d = 1, d = 2$ arba $d = 3$.

Yra išskiriami *tiesinės* ir *netiesinės projekcijos* metodai.

Tiesinės projekcijos metodais ieškoma tiesinės analizuojamų duomenų transformacijos, o netiesinės projekcijos – netiesinės transformacijos.

Bendru atveju yra įvairių tiesinės transformacijos galimybių: pasukimas, postūmis, atspindys, suspaudimas ir kt.

Pasukimo tipo tiesinė transformacija yra aprašoma tiesinių lygčių sistema

$$Y_i = X_i A.$$

Bendru atveju $Y_i = (y_{i1}, y_{i2}, \dots, y_{in})$, $X_i = (x_{i1}, x_{i2}, \dots, x_{in})$, A – kvadratinė matrica, sudaryta iš n eilučių ir n stulpelių.

Jei tiesinė transformacija naudojama duomenų matmenų skaičiui mažinti, tada $Y_i = (y_{i1}, y_{i2}, \dots, y_{id})$, $d < n$, A – matrica, sudaryta iš n eilučių ir d stulpelių.

Netiesinė projekcija yra aprašoma šia forma:

$$Y = f(X),$$

čia f yra netiesinė transformacija.

Netiesinė projekcija yra sudėtingesnė, reikalauja kur kas didesnių skaičiavimų.

Formuluojami ir sprendžiami daugelio kintamųjų optimizavimo uždaviniai, kurie dažniausiai būna daugiaekstremiai.

Panagrinėkime elementarų tiesinės projekcijos atvejį, kai $n = 2$. Tegul turime tašką $X_i = (x_{i1}, x_{i2})$. Transformuokime jį į tašką $Y_i = (y_{i1}, y_{i2})$ tiesine transformacija

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}.$$

Matricos A elementai šiuo atveju priklauso tik nuo pasukimo kampo ir gali būti išreikšti per trigonometrines funkcijas:

$$A = \begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix},$$


čia α yra kampas tarp ašių x_1 ir y_1 , tuo pačiu ir tarp ašių x_2 ir y_2 , t. y. koordinačių sistemą (x_1, x_2) kampu α pasukame prieš laikrodžio rodyklę kad gautume koordinačių sistemą (y_1, y_2) . Koordinačių pradžios taškas nepasikeičia.

Taško X_i koordinatės sistemoje (x_1, x_2) yra (x_{i1}, x_{i2}) , o naujoje sistemoje yra (y_{i1}, y_{i2}) :

$$y_{i1} = x_{i1} \cos \alpha + x_{i2} \sin \alpha, \quad y_{i2} = x_{i2} \cos \alpha - x_{i1} \sin \alpha.$$

Faktiškai $Y_i = (y_{i1}, y_{i2})$ ir yra taško X_i tiesinė transformacija į koordinačių sistemą (y_1, y_2) . Jei mūsų tikslas yra sumažinti duomenų matmenų skaičių, tai vektorių Y_i galime sudaryti tik iš vienos koordinatės, pavyzdžiui, $Y_i = (y_{i1})$. Tada gausime taško X_i transformaciją į vienmatę erdvę.

Tiesinės transformacijos (pasukimo) pavyzdys




Netiesinės transformacijos privalumai

Dvimačiai taškai $X_1, X_2, \dots, X_8$ išdėstyti taip, kad tarp artimiausių taškų yra vienodi atstumai, t. y.


$$d(X_i, X_{i+1}) = d(X_{i+1}, X_{i+2}), \quad i = 1, \dots, 6.$$

Jei juos atvaizduosime į vienmatę erdvę (į tiesę y_1) naudodamiesi tiesine projekcija, atstumai tarp taškų nebus išlaikyti.

Netiesinės projekcijos atveju, radus tinkamą transformaciją, atstumai tarp artimiausių taškų išliks vienodi.



Tiesinė



Netiesinė

Pagrindinių komponentų analizė (*principal component analysis, PCA*)

Tai tiesinė duomenų transformacija, plačiai naudojama duomenų analizei kaip daugiamatinių duomenų matmenų skaičiaus mažinimo metodas.


Esminė PKA idėja yra sumažinti duomenų matmenų skaičių atliekant tiesinę transformaciją ir atsisakant dalies po transformacijos gautų naujų komponentų, kurių dispersijos yra mažiausios

Iš pradžių ieškoma krypties, kuria dispersija yra didžiausia. Didžiausią dispersiją turinti kryptis vadinama pirmąja pagrindine komponente (PK1).

Ji eina per duomenų centrinį tašką. Tai taškas, kurio komponentės yra analizuojamą duomenų aibę sudarančių taškų atskirų komponentų vidurkiai. Visų taškų vidutinis atstumas iki šios tiesės yra minimalus, t. y. ši tiesė yra kiek galima arčiau visų duomenų taškų.

Antrosios pagrindinės komponentės (PK2) ašis taip pat turi eiti per duomenų centrinį tašką ir ji turi būti statmena pirmosios pagrindinės komponentės ašiai. Ir t.t.

Pirmoji (PK1) ir antroji (PK2) pagrindinės komponentės



Tegul turime duomenų matricą

$$X = \{X_1, X_2, \dots, X_m\} = \{x_{ij}, i = 1, \dots, m, j = 1, \dots, n\},$$

kurios i -oji eilutė yra vektorius $X_i = (x_{i1}, x_{i2}, \dots, x_{in})$.

Faktiškai šios matricos eilutės žymi objektus,
o stulpeliai – tuos objektus apibūdinančius parametrus (požymius).

Apskaičiuokime *koreliacijos koeficientą*.

Koreliacija – tai dviejų parametrų tarpusavio sąryšis.

Parametrų x_k ir x_l koreliacijos koeficientas r_{kl} tarp yra skaičiuojamas taip:

$$r_{kl} = \frac{\sum_{i=1}^m (x_{ik} - \bar{x}_k)(x_{il} - \bar{x}_l)}{\sqrt{\sum_{i=1}^m (x_{ik} - \bar{x}_k)^2 \sum_{i=1}^m (x_{il} - \bar{x}_l)^2}}$$

$$\bar{x}_k = \frac{1}{m} \sum_{i=1}^m x_{ik} \quad \bar{x}_l = \frac{1}{m} \sum_{i=1}^m x_{il}$$

Iš koreliacijos koeficientų galima sudaryti *koreliacinę matricą*

$$R = \{r_{kl}, k, l = 1, \dots, n\}.$$

Matricos R įstrižinės elementai r_{kk} , $k = 1, \dots, n$, lygūs vienetui.

Parametrų x_k ir x_l kovariacijos koeficientas c_{kl} yra skaičiuojamas:

$$c_{kl} = \frac{1}{m-1} \sum_{i=1}^m (x_{ik} - \bar{x}_k)(x_{il} - \bar{x}_l). \quad (1)$$

Kai $k = l$, išraiška (1) yra dispersijos formulė, t. y. c_{kk} yra duomenų aibės parametro x_k dispersija.

Iš kovariacijos koeficientų, gautų remiantis (1) formule, galima suformuoti *kovariacinę matricą* $C = \{c_{kl}, k, l = 1, \dots, n\}$.

Ši matrica yra simetrinė.

Parametrų k ir l koreliacijos koeficientas

$$r_{kl} = \frac{c_{kl}}{\sqrt{c_{kk}c_{ll}}}.$$

Jei parametrai x_k ir x_l nekoreliuoti, tai jų kovariacijos koeficientas lygus 0:

$$c_{kl} = c_{lk} = 0, k \neq l.$$

Apibrėžkime kovariacinės matricos tikrinius vektorius ir jų tikrines reikšmes.

Matricos *tikrinis vektorius (eigenvector)* E_k ir jį atitinkanti *tikrinė reikšmė (eigenvalue)* λ_k yra lygties

$$CE_k = \lambda_k E_k$$

sprendinys.

E_k yra vektorius stulpelis, C – kovariacinė matrica.

λ_k reikšmė randama iš charakteristinės lygties $|C - \lambda_k I| = 0$.

Čia I yra vienetinė matrica, kurios matmenys tokie pat kaip matricos C ; ženklu $|\cdot|$ apibrėžtas determinantas.

Tikrinių vektorių skaičius yra lygūs duomenų matricą X sudarančių vektorių komponenčių skaičiui n .

Rasti tikrinius vektorius ir tikrines reikšmes nėra trivialus uždavinys, tačiau yra sukurta nemažai šio uždavinio sprendimo metodų.

Surūšiuokime tikrinius vektorius E_k juos atitinkančių tikrinių reikšmių mažėjimo tvarka ($\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \dots \geq \lambda_n$).

Matrica $A = (E_1, E_2, \dots, E_n)$ yra vadinama pagrindinių komponentų matrica. Jos stulpeliai yra tikriniai vektoriai E_k , $k = 1, \dots, n$, atitinkantys tikrines reikšmes $\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \dots \geq \lambda_n$.

Kiekvienas matricos A vektorius stulpelis yra ortogonalus bet kuriam kitam.

Transformuokime duomenų vektorius X_i , $i = 1, \dots, m$, pagal šią formulę:

$$Y_i = (X_i - \bar{X})A, \quad (2)$$

čia $X_i = (x_{i1}, x_{i2}, \dots, x_{in})$, $\bar{X} = (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{in})$, $A = (E_1, E_2, \dots, E_n)$.

Iš (2) formulės gauti $Y_i = (y_{i1}, y_{i2}, \dots, y_{in})$ yra vektoriai (taškai) naujoje ortogonalioje koordinačių sistemoje $(y_1, y_2, \dots, y_n)$, apibrėžtoje tikriniais vektoriais E_k , $k = 1, \dots, n$.

Vektorių Y_i , $i = 1, \dots, m$, komponentų $y_1, y_2, \dots, y_n$ kovariacinė matrica

$$C_y = \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix}.$$

Duomenų vektorius X_i , $i = 1, \dots, m$, galima išreikšti per vektorius Y_i :

$$X_i = Y_i A^T + \bar{X} . \quad (3)$$

Formulė (3) gauta iš (2) pritaikius ortogonalų matricų savybę, kad $A^{-1} = A^T$, čia A^{-1} yra atvirkštinė, A^T – transponuota matrica.

Daugiamačių duomenų transformacijai galima naudoti ne visus tikrinius vektorius, o tik pirmuosius.

Tegul matrica A_d yra sudaryta iš d pirmųjų tikrinių vektorių.

Tada galima sukurti transformaciją, analogišką (2) išraiškai:

$$Y_i = (X_i - \bar{X}) A_d , \quad i = 1, \dots, m .$$

Tokiu būdu randama duomenų vektoriaus projekcija į d matmenų erdvę.

Vizualizavimui paprastai pasirenkame $d = 2$ arba $d = 3$.

Tikrinių reikšmių $\lambda_1, \lambda_2, \dots, \lambda_n$ savybės:

- 1) $\sum_{k=1}^n \lambda_k = \sum_{k=1}^n c_{kk}$;
- 2) $\lambda_1 = \max_k \lambda_k \geq \max_k c_{kk}$;
- 3) $\lambda_n = \min_k \lambda_k \leq \min_k c_{kk}$;

čia c_{kk} yra duomenų aibės parametro x_k dispersija, o tikrinė reikšmė λ_k yra transformuotų duomenų parametro y_k dispersija.

Iš antros savybės seka, kad

- pirmasis tikrinis vektorius E_1 aprašo naują parametą y_1 , kurio dispersija λ_1 yra pati didžiausia tarp $\lambda_1, \lambda_2, \dots, \lambda_n$, t. y. šis parametras ir yra pirmoji pagrindinė komponentė,
- antrasis tikrinis vektorius E_2 aprašo parametą y_2 , kurio dispersija yra antra pagal dydį ir kuris yra antroji pagrindinė komponentė, ir t. t.

Iš trečios savybės seka, kad paskutinis tikrinis vektorius E_n aprašo parametą y_n , kurio dispersija bus pati mažiausia.

Naudojant tik d pirmųjų tikrinių vektorių, bus atsisakyta tos dalies po transformacijos gautų naujų parametų (požymių), kurių dispersijos yra mažiausios.


PKA metodo taikymo pavyzdžiai

Pirmos veislės irisai (pažymėti juodai) „nutolę“ nuo kitų dviejų veislių, ryškos ribos tarp kitų dviejų veislių nėra.


Didžioji dalis taškų, atitinkančių nepiktybinio naviko duomenis (juodi taškai), susikoncentruoja vienoje srityje, o kiti taškai, atitinkantys piktybinio naviko duomenis, pasiskirsto plačiai. Abiem atvejais stebime aiškiai išskiriančias taškų sankaupos sritis.

Pagrindinių komponentų metodo privalumas yra jo idėjos paprastumas. Tai didžia dalimi nulėmė jo populiarumą ir platų taikymą.

Irisų duomenys



Krūties vėžio duomenys



Jeigu PKA metodas naudojamas ne duomenims vizualizuoti, kyla klausimas, kiek pagrindinių komponentų d reikia parinkti.

Dauguma skaičiaus d parinkimo taisyklių yra neformalios.

Galima parinkti tokį mažiausią skaičių d , kad procentinis dydis nuo visos dispersijos viršytų tam tikrą pasirinktą lygį, pavyzdžiui, 90%.

Jei pagrindinių komponentų analizėje, užuot naudojęsi kovariacine matrica, galima rinktis koreliacinę matricą. Tai yra ekvivalentu tam tikram parametrų $x_1, x_2, \dots, x_n$ normavimui, o tik po to naujų parametrų (pagrindinių komponentų) $y_1, y_2, \dots, y_d$ paieškai.

Jei egzistuoja tiesinės priklausomybės tarp parametrų $x_1, x_2, \dots, x_n$, tai, taikant pagrindinių komponentų metodą, duomenų matmenų skaičius mažinamas su nedidelėmis paklaidomis.

Tačiau bendru atveju gali egzistuoti netiesinės priklausomybės, kurių PKA metodas negali įvertinti, ir tai yra šio metodo trūkumas.

Vizualizavimo rezultatai, gauti taikant PKA metodą, labai priklauso nuo taškų atsiskyrėlių, nes šie taškai n -matėje erdvėje yra ryškiai nutolę nuo kitų, ir tai daro didelę įtaką kovariacinės matricos C elementų reikšmėms, kartu ir nustatytoms pagrindinėms komponentėms bei duomenų projekcijos kokybei visumoje.

Netiesinės projekcijos metodai – Daugiamatės skalės

Daugiamačių skalių (DS, *multidimensional scaling*, MDS) – tai grupė metodų, plačiai naudojamų daugiamačių duomenų analizei. Gausu šio metodo realizacijų, kurios skiriasi naudojamais vizualizavimo kokybės kriterijais, optimizavimo algoritmais ar prielaidomis apie duomenis.

Vienas daugiamačių skalių metodų tikslų yra rasti optimalų daugiamačius objektus atitinkančių taškų (vektorių) vaizdą mažo skaičiaus matmenų erdvėje.

Naudojantis DS, ieškoma daugiamačių duomenų projekcijų mažesnio skaičiaus matmenų erdvėje (dažniausiai R^2 arba R^3), siekiant išlaikyti analizuojamos aibės objektų artimumus – panašumus arba skirtingumus. Projektijoje panašūs objektai išdėstomi arčiau vieni kitų, o skirtingi – toliau vieni nuo kitų.

Pradiniai daugiamačių skalių metodo duomenys yra kvadratinė simetrinė matrica, kurios elementai nusako artimumą tarp analizuojamų objektų. Tai gali būti arba panašumų, arba skirtingumų matrica. Paprasčiausiu atveju tai yra Euklido atstumų tarp objektų matrica. Tačiau bendruoju atveju, tai nebūtinai turi būti atstumai griežtai matematine prasme.

Naudojant daugiamačių skalių metodą, ne tik daugiamačiai vektoriai, bet ir bendresnės daugiamačių duomenų aibės gali būti vizualizuojamos, nes pakankami duomenys šiam metodui yra objektų *artimumas*, apibrėžtas objektų porų *skirtingumu*.

Objektų skirtingumas gali būti įvertinamas psichologiniuose tyrimuose. Tokių duomenų matmenų (parametrų) skaičius gali būti nežinomas, skirtingumas gali neturėti metrinų savybių, pavyzdžiui jam gali negaloti trikampo nelygė.

Jei duomenys pateikiami daugiamačiais vektoriais, jų skirtingumas įvertinamas atstumu daugiamatėje *duomenų erdvėje*.

DS metodo esmė – minimizuoti *įtempimo funkciją*, kuria naudojantis lyginami objektų skirtingumai su atstumais tarp tuos objektus atvaizduojančių taškų *vaizdo erdvėje*

Tarkime, kiekvieną n -matį vektorių $X_i \in R^n$, $i \in \{1, \dots, m\}$, atitinka mažesnio skaičiaus matmenų vektorius $Y_i \in R^d$, $d < n$.

Atstumą (skirtingumą) tarp vektorių X_i ir X_j pažymėkime $d(X_i, X_j)$, o atstumą tarp vektorių Y_i ir Y_j pažymėsime $d(Y_i, Y_j)$, $i, j = 1, \dots, m$.

Naudojantis MDS algoritmu, bandoma atstumus $d(Y_i, Y_j)$ atrasti kuo artimesnius atstumams $d(X_i, X_j)$.

Jei naudojama kvadratinė paklaidos funkcija, tai minimizuojama tikslo funkcija E_{DS} gali būti užrašyta taip:

$$E_{DS} = \sum_{i < j} w_{ij} \left(d(X_i, X_j) - d(Y_i, Y_j) \right)^2 .$$

Paklaidos funkcija E_{DS} dar vadinama *Stress* funkcija. Dažnai naudojami tokie svoriai w_{ij} :

$$w_{ij} = \frac{1}{\sum_{i < j} \left(d(X_i, X_j) \right)^2} ,$$

$$w_{ij} = \frac{1}{d(X_i, X_j) \sum_{k < l} d(X_k, X_l)} ,$$

$$w_{ij} = \frac{1}{m d(X_i, X_j)} ,$$

čia $d(X_i, X_j) \neq 0$, t. y. tarp vektorių $X_1, X_2, \dots, X_m$ nėra sutampančių.

Objektų vaizdas randamas minimizuojant įtempimo funkciją: d -matėje erdvėje ieškoma tokių m taškų koordinačių, kad įtempimo funkcija būtų minimali.

Matematiškai optimizavimo uždavinys formuluojamas taip: reikia rasti netiesinės $m \times d$ tolydžiųjų kintamųjų funkcijos (vadinamosios tikslo funkcijos)

$$f(Y): R^{m \times d} \rightarrow R \text{ minimumą}$$

$$f^* = \min f(Y),$$


ir globalaus minimumo tašką Y^* , kuriame funkcijos reikšmė lygi funkcijos minimumui:

$$Y^*: f(Y^*) = f^*.$$


Įtempimo funkciją minimizuoti gan sudėtinga, nes:

- yra daug lokalių minimumų taškų, o interpretuojant skirtingus lokalių minimumų taškus atitinkančius vaizdus gaunami skirtingi rezultatai, dėl to svarbu rasti globalų minimumą ir jį atitinkantį vaizdą;
- praktinių uždavinių minimizavimo kintamųjų skaičius $m \times d$ paprastai yra didelis;
- įtempimo funkcija yra ne visur diferencijuojama;

įtempimo funkcija yra invariantinė perkėlimo, sukimo ir atspindžių atžvilgiu, t. y. analizuojant pateiktus duomenis vizualiai nėra svarbu, ar jų visuma bus paslinkta, ar pasukta, ar pateiktas jos atspindys kokios nors ašies atžvilgiu



MDS metodu vizualizuoti irisų duomenys



MDS metodu vizualizuoti krūties vėžio duomenys

ISOMAP

Šis metodas skiriasi nuo įprastinio DS metodo tuo, kad atstumų tarp analizuojamų objektų matas yra apibrėžiamas kitaip.

Taikant ISOMAP metodą, daroma prielaida, kad pradinėje erdvėje analizuojamus duomenis atitinkantys taškai yra išsidėstę ant mažesnio skaičiaus matmenų netiesinės daugdaros, ir todėl skaičiavimuose naudojami geodeziniai atstumai.

Daugdara (manifold) – tai abstrakti topologinė matematinė erdvė, kurioje kiekvieno taško aplinka yra labai panaši į Euklido erdvę, tačiau šios erdvės globali struktūra daug sudėtingesnė.


Plokštuma, sferos paviršius, toro paviršius yra dvimatės daugdaros (*toras*, arba *toroidas*, geometrijoje yra sukimosi paviršius, kurį apibrėžia apskritimas, besisukantis aplink lygiagrečią su jo plokštuma ir jo neliečiančią ašį). Žemės paviršių taip pat galima laikyti dvimate daugdara.

Anksčiau nagrinėtuose metoduose atstumams tarp vektorių skaičiuoti paprastai yra naudojami Euklido atstumai. Skaičiuojant atstumus neatsižvelgiama į daugdaros formą. Tuomet susiduriama su sunkumais atvaizduojant netiesines duomenų struktūras, kaip kad spiralę ar pan.


ISOMAP metode artimumo tarp vizualizuojamų objektų (taškų) matas yra geodezinis atstumas.

Geodezinis, arba *kreivinis*, *atstumas* – tai trumpiausio kelio ilgis einant daugdaros kreivu paviršiumi. Euklido atstumas tarp dviejų taškų parodytas a paveiksle, o b paveiksle pavaizduotas geodezinis atstumas tarp tų pačių taškų.

Norint apskaičiuoti geodezinius atstumus tarp duomenų taškų $X_1, X_2, \dots, X_m$, pirmiausia reikia nustatyti kiekvieno taško X_i , $i \in \{1, \dots, m\}$, artimiausius taškus, kuriuos vadinsime taškais kaimynais.



a)



b)

Kaimynų paieškoje artimumo matas yra Euklido atstumas.

Taškų kaimynų paieška gali būti organizuojama dvejopai:

- arba ieškoma nustatyto skaičiaus kaimynų,
- arba ieškoma kaimynų iš tam tikro fiksuoto dydžio spindulio hipersferos, kurios centras yra taškas X_i .

Tuomet sudaromas svorinis grafas, kuris jungia kiekvieną tašką X_i , $i \in \{1, \dots, m\}$, su visais jo kaimynais.

Grafo briaunų svoriai yra atstumai tarp taško X_i ir jo kaimynų.

Randami trumpiausią kelių ilgiai tarp visų taškų porų.

Šie ilgiai ir yra geodezinių atstumų tarp taškų porų įverčiai.

Geodezinių atstumų matrica, kuri yra laikoma skirtingumo tarp analizuojamų objektų matrica.


Šią matricą galima analizuoti bet kuriuo daugiamačių skalių metodu.

Taikant ISOMAP metodą ieškoma tokios transformacijos į vaizdo erdvę, kur būtų geriausiai išlaikomi geodeziniai atstumai tarp vizualizuojamų objektų (taškų).


ISOMAP algoritmą sudaro trys etapai:

1. Daugiamatėje erdvėje randami kiekvieno taško kaimynai.
2. Skaičiuojami geodeziniai atstumai tarp visų taškų porų; suformuojama skirtingumų matrica.
3. Daugiamačių skalių metodu randamos daugiamačių taškų projekcijos mažesnio skaičiaus matmenų – vaizdo erdvėje.


a)




b)



c)




d)



S raidės daugdaros pavyzdys: a) daugdara, b) taškai ant daugdaros, c) projekcija, gauta ISOMAP metodu, d) projekcija, gauta įprastiniu MDS metodu

Lokaliai tiesinis vaizdavimas (locally linear embedding, LLE)

Šiuo metodu atvaizduojant daugiamačius duomenis į mažesnio skaičiaus matmenų erdvę, išlaikomi kaimynystės ryšiai tik tarp artimiausių taškų, bet atskleidžiama netiesinės daugdaros globali struktūra.



Algoritmą sudaro trys etapai:

- Nustatoma kiekvieno vizualizuojamo duomenų taško X_i , $i \in \{1, \dots, m\}$, k artimiausių kaimynų. Artimumo matas yra Euklido atstumas. Taškų kaimynų paieška gali būti organizuojama dvejopai: arba ieškoma nustatyto skaičiaus kaimynų, arba ieškoma kaimynų iš tam tikro fiksuoto dydžio spindulio hipersferos, kurios centras yra taškas X_i .
- Kiekvienas daugiamatis taškas X_i išreiškiamas jo kaimynų tiesine kombinacija

$$X_i = \sum_{j=1}^m w_{ij} X_j,$$

čia svoriai $w_{ij} \neq 0$, jei taškas X_j yra taško X_i kaimynas, ir $w_{ij} = 0$, jei taškai X_i ir X_j nėra kaimynai. Svoriai w_{ij} turi būti parinkti taip, kad paklaida

$$E(W) = \sum_{i=1}^m \left(X_i - \sum_{j=1}^m w_{ij} X_j \right)^2$$

būtų minimali. Svoriai turi tenkinti sąlygą, kad visiems i

$$\sum_{j=1}^m w_{ij} = 1.$$

- Radus tinkamus svorius w_{ij} , projekcijos vektoriai Y_i , $i = 1, \dots, m$, apskaičiuojami minimizuojant paklaidą

$$\Phi(Y) = \sum_{i=1}^m \left(Y_i - \sum_{j=1}^m w_{ij} Y_j \right)^2$$

ir esant apribojimams


$$\sum_{i=1}^m Y_i = 0, \quad \frac{1}{m} \sum_{i=1}^m Y_i^T Y_i = I,$$

čia I – vienetinė matrica, sudaryta iš d eilučių ir d stulpelių, Y_i^T – transponuotas vektorius Y_i . Paprasčiausias būdas apskaičiuoti vektorių Y_i , $i = 1, \dots, m$, d -mės komponentes yra rasti išretintos matricos

$$\bar{M} = (I - W)^T (I - W)$$

d tikrinių vektorių, atitinkančių mažiausias nenulines d tikrines reikšmes, čia I – vienetinė matrica, sudaryta iš m eilučių ir m stulpelių, $W = \{w_{ij}, i, j = 1, \dots, m\}$. Šie d tikriniai vektoriai ir yra vektoriai Y_i , $i = 1, \dots, m$.

Lokaliai tiesinio vaizdavimo algoritmo schema






Lokaliai tiesinio vaizdavimo metodas dažnai yra taikomas vizualizuoti daugiamačius vektorius, kurių komponentių reikšmės atitinka paveikslėlių ar nuotraukų parametrus.

Iš analizuojamo paveikslėlio ar nuotraukos taškų spalvinių savybių sudaromas vektorius, kurio matmenų skaičius yra labai didelis.






Analizuojamų duomenų aibė ypatinga tuo, kad ją sudaro vektoriai, atitinkantys kelis to paties objekto, pasukto tam tikrais kampais, paveikslėlius ar nuotraukas.

Tuo atveju vektoriai vienas nuo kito nedaug skiriasi ir jie sudaro tam tikrą daugdarą.






Lokaliai tiesinio vaizdavimo metodu vizualizuoti besisukančio ančiuko paveikslėlių duomenys




Up-and-down pose




Left-and-right pose

Lightening direction



Left-and-right pose

Lightening direction





Up-and-down pose



Self-organizing Maps (SOM)


The SOM is a class of neural networks that are trained in an unsupervised manner, using competitive learning. It is a well-known method for mapping a high-dimensional space onto a low-dimensional one.

We consider here a mapping onto a two-dimensional grid of neurons. Let $X_1, X_2, \dots, X_m \in R^n$ be a set of n -dimensional vectors for mapping. Usually, the neurons are connected to each other via a rectangular (a) or hexagonal topology (b).



The rectangular SOM is a two-dimensional array of neurons $M = \{m_{ij}, i = 1, \dots, k_x, j = 1, \dots, k_y\}$. Here k_x is the number of rows, and k_y is the number of columns.

Each component of the input vector is connected to every individual neuron.





Self-organizing Maps (SOM)

- The learning starts from the vectors m_{ij} initialized randomly.
- At each learning step, an input vector X is passed to the neural network.
 - the Euclidean distance from this input vector to each vector m_{ij} is calculated and the vector (neuron) m_c with the minimal Euclidean distance to X is designated as a winner;
 - the components of the vector m_{ij} are adapted according to the rule

$$m_{ij} \leftarrow m_{ij} + h_{ij}^c (X - m_{ij}), \text{ where } h_{ij}^c = \frac{\alpha}{\alpha \eta_{ij}^c + 1} \quad \alpha = \max \left(\frac{e + 1 - \hat{e}}{e}, 0.01 \right)$$



η_{ij}^c is the neighbourhood order between the neurons m_{ij} and m_c .

e is the number of training epochs. The epoch consists of s learning steps: the input vectors are passed to the neural network.

t is the order number of current epoch.

We recalculate the vector m_{ij} if $\eta_{ij}^c \leq \max[\alpha \max(k_x, k_y), 1]$.

Self-organizing maps (SOM)



Analysis of the economic and social conditions of Lithuania and neighboring countries

10 countries

6 parameters

1	Hungary
2	Czech Republic
3	Lithuania
4	Latvia
5	Slovakia
6	Poland
7	Romania
8	Estonia
9	Bulgaria
10	Slovenia

x_1 - the infant mortality rate (deaths / 1000 live births)

x_2 - the Gross Domestic Product (GDP) per capita in US dollars obtained taking into account the purchasing power parity of the national currency but not the exchange rate


x_3 - the percentage of GDP developed in the industry and services (not in the agriculture)

x_4 - the export per capita in thousands of US dollars

x_5 - the number of telephones per capita


x_6 - the international aid in US dollars per capita

Projection of countries from the view of economic and social parameters



Countries

3	Lithuania
4	Latvia
8	Estonia
6	Poland



Distribution of countries, 3x3 and 4x4 SOM

Countries

3	Lithuania
4	Latvia
8	Estonia
6	Poland

MAX,2,10		1, 5, 6
	AVE	
MIN, 7	9	3, 4, 8

MAX, 10			MIN, 7
2			9
5			3
1	6	AVE	4, 8

Combining the SOM and MDS

- The self-organizing map provides a structured information about the set of the analysed vectors: several elements (neurons) of the two-dimensional rectangular grid are activated (become winners), while the remaining elements are not activated.
- The activated elements of the grid may be considered as points on the plane. The location of these elements is fixed on the plane by the nodes of a grid. However, n -dimensional vectors m_{ij} characterize the elements, too.
- A natural idea arises to apply the distance-preserving projection method to additional mapping of the neurons-winners, in the SOM. Sammon's mapping may be used for such purposes.

Various scenarios of visualization of the n -dimensional vectors $X_1, \dots, X_m \in R^n$ are possible:

- Multidimensional scaling (Sammon's mapping);
- its consequent combination with the SOM (the SOM vectors-winners are displayed using Sammon's projection);
- integrated combination of the SOM and Sammon mapping, where vectors $X_1, \dots, X_m \in R^n$ are analysed by using Sammon's mapping taking into account the process of SOM training.

The idea of integrated combination:


- The total number of the training epochs e is divided into γ equal training blocks.
- The n -dimensional vectors-winners in the SOM, obtained after the q -th block ($q=1, \dots, \gamma$), are analyzed by Sammon's mapping, where the initial coordinates of two-dimensional vectors for Sammon's mapping are selected by the results of the previous block.

Integrated combination of the SOM and MDS



We analyze the algorithm for multidimensional data visualization combining the SOM and MDS (Sammon's mapping), taking into account the learning flow of the SOM.

- n -dimensional vectors are projected onto the plane.
- The total number of the training epochs e is divided into γ equal training blocks.
- n -dimensional vectors $X_1, X_2, \dots, X_m \in R^n$ are passed to the SOM.
- The n -dimensional vectors-winners in the SOM, obtained after the q -th block ($q=1, \dots, \gamma$), are analyzed by Sammon's mapping, where the initial coordinates of two-dimensional vectors for Sammon's mapping are selected by the results of the previous block.

Integrated combination of the SOM and MDS





Integrated combination of the SOM and MDS



Countries

3	Lithuania
4	Latvia
8	Estonia
6	Poland

Results of mapping



Countries

3	Lithuania
4	Latvia
8	Estonia
6	Poland

Categories of dimensionality reduction algorithms depending on the distance preservation

Dimension reduction algorithms tend to fall into two categories:

1. That seek to preserve the pairwise distance structure amongst all the data samples (PCA , MDS, and Sammon mapping)
2. That favor the preservation of local distances over global distances (Isomap, LargeVis, Locally linear embedding, Laplacian eigenmaps, t-SNE, UMAP, and diffusion maps.

UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction

Uniform Manifold Approximation and Projection (UMAP) is a dimension reduction technique that can be used for visualisation similarly to t-SNE, but also for general non-linear dimension reduction. The algorithm is founded on three assumptions about the data:

1. There exists a manifold on which the data would be uniformly distributed.
2. The underlying manifold of interest is locally connected.
3. Preserving the topological structure of this manifold is the primary goal.

From these assumptions it is possible to model the manifold with a fuzzy topological structure. The embedding is found by searching for a low dimensional data projection with the closest possible equivalent fuzzy topological structure.

McInnes, L, Healy, J, *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*, ArXiv e-prints 1802.03426, 2018

UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction

The inputs are:

X , the dataset to have its dimension reduced;

k , the neighborhood size to use for local metric approximation;


d , the dimension of the target reduced space;

min-dist, an algorithmic parameter controlling the layout;

v-epochs, controlling the amount of optimization work to perform.

Practical implementation of this algorithm requires (approximate) k -nearest neighbor calculation and efficient optimization via stochastic gradient descent.

Weakness: One of the core assumptions of UMAP is that there exists manifold structure in the data. If global structure is of primary interest, then UMAP may not be the best choice for dimension reduction. Multi-dimensional scaling (MDS) specifically seeks to preserve the full distance matrix of the data, and as such is a good candidate when all scales of structure are of equal importance.



Paveiksle vietoje k yra naudojamas n, kaip originaliame straipsnyje

t-SNE: t-distributed stochastic neighbor embedding

t-SNE is a nonlinear dimensionality reduction technique for embedding high-dimensional data for visualization in a low-dimensional space of two or three dimensions. Turi panašumų su LLE (Locally linear embedding)

Van der Maaten, L.J.P.; Hinton, G.E. (Nov 2008). "Visualizing Data Using t-SNE" (PDF). *Journal of Machine Learning Research*. 9: 2579–2605.

The t-SNE algorithm comprises two main stages:

1. t-SNE constructs a probability distribution over pairs of high-dimensional objects so that similar objects are assigned a higher probability while dissimilar points are assigned a lower probability.
2. t-SNE defines a similar probability distribution over the points in the low-dimensional map, and it minimizes the divergence between the two distributions with respect to the locations of the points in the map. While the original algorithm uses the Euclidean distance between objects as the base of its similarity metric, this can be changed as appropriate. A Riemannian variant is UMAP.

Control parameter *Perp* represents the perplexity (nuspėjamumas, neatitikimas duomenims) of the conditional probability distribution induced by a Gaussian kernel.

Like many other visualization techniques, t-SNE has a computational and memory complexity that is quadratic in the number of datapoints. This makes it infeasible to apply the standard version of t-SNE to datasets that contain many more than, say, 10,000 points.

t-SNE, like other nonlinear visualization methods, can be modified to display a random subset of the data points (so-called landmark points) in a way that uses information from the entire (possibly very large) data set.

t-SNE reduces the dimensionality of data mainly based on local properties of the data.


In data sets with a high intrinsic dimensionality and an underlying manifold that is highly varying, the local linearity assumption on the manifold that t-SNE implicitly makes (by employing Euclidean distances between near neighbors) may be violated.

t-SNE has three potential weaknesses:

- (1) it is unclear how t-SNE performs on general dimensionality reduction tasks,
- (2) the relatively local nature of t-SNE makes it sensitive to the curse of the intrinsic dimensionality of the data,
- (3) t-SNE is not guaranteed to converge to a global optimum of its cost function.




(a) Visualization by t-SNE.




(b) Visualization by Sammon mapping.

Sammon mapping – tas pats MDS, tik su svorių svoriais stress funkcijoje, kad padaryti svarbesniais daugiamačių erdvės mažus atstumus



(c) Visualization by Isomap.



(d) Visualization by LLE.